

Preguntas de Exámen

NAIVE BAYES / NLP BÁSICO

Ejercicio 1

Suponga que tiene el siguiente conjunto de datos, y debe realizar una tarea de procesamiento de lenguaje natural con Bayes Naive:

Documento	Palabras	Clase
1	Star Wars	A
2	Star Wars Game	A
3	Star Trek	B
4	Star estrella	?

Calcule los siguientes valores pedidos, asumiendo que se utiliza Laplace Smoothing (puede dejar indicadas las fracciones):

a) Vocabulario: _____ b) $p(\text{Clase A}) =$ _____ c) $p(\text{Clase B}) =$ _____ d)
 $p(\text{"estrella"} \mid \text{clase A}) =$ _____

Ejercicio 2

Suponga que tiene el siguiente conjunto de datos, y debe realizar una tarea de procesamiento de lenguaje natural con Bayes Naive:

Documento	Palabras en el documento	Clase
1 (entrenamiento)	Hola Chau	Clase A
2 (entrenamiento)	Chau Chau Chau	Clase B
3 (prueba)	desfibrilador	???

Indique cuál es la "probabilidad" condicional de la palabra "desfibrilador" de pertenecer a la clase A, utilizando Laplace Smoothing. Marque con una cruz la respuesta correcta.

- ☐ $p(\text{desfibrilador} \mid \text{clase_A}) = 0$
- ☐ $p(\text{desfibrilador} \mid \text{clase_A}) = 0.2$
- ☐ $p(\text{desfibrilador} \mid \text{clase_A}) = 0.5$
- ☐ $p(\text{desfibrilador} \mid \text{clase_A}) = 1$

Ejercicio 3

Suponga que tiene el siguiente conjunto de datos, y debe realizar una tarea de procesamiento de lenguaje natural con Naive Bayes:

Documento	Palabras	Clase
1	gran obra	POS
2	muy divertida	POS
3	horrible obra	NEG
4	obra terriblemente mala	NEG
5	obra terriblemente divertida	???

Calcule los siguientes valores pedidos, asumiendo que se utiliza Laplace Smoothing (puede dejar indicadas las fracciones):

a) Vocabulario: _____ b) $P(\text{Clase POS}) = \text{_____}$ y $P(\text{Clase NEG}) = \text{_____}$ c) $P(\text{POS} | \text{docs}) = \text{_____}$ y $P(\text{NEG} | \text{docs}) = \text{_____}$ d) ¿A qué clase pertenece según los valores antes calculados? _____

ANÁLISIS DE SENTIMIENTOS, BAG OF WORDS Y LEXICONES

- ¿Qué es un Lexicón o diccionario de sentimientos y cómo lo utilizaría en una tarea de análisis de sentimientos? ¿Qué ventajas y desventajas tiene respecto a entrenar un clasificador desde cero?
- Dado un lexicón de sentimientos con palabras y su correspondiente puntaje positivo/negativo: ¿qué se debe hacer antes de usar el lexicón? Dar puntaje positivo/negativo de documentos (oraciones) dadas.
- Dado un texto y un lexicón con puntaje de clasificación positiva o negativa, reconocer los aspectos en el texto, puntuarlos y explicar cómo se hizo.
- ¿Qué son los "aspectos" en una tarea de análisis de sentimiento? Dar ejemplos.
- ¿Es posible detectar otras emociones además de "positiva" o "negativa" en una porción de texto en lenguaje natural? Dar ejemplos si la respuesta es afirmativa.
- ¿En qué consiste la técnica de Bag Of Words?

Ejercicio (opción múltiple): Se tienen los siguientes documentos, los cuales se desean tratar utilizando Bag of Words:

Documento	Texto
1	El mejor clima, fue el mejor clima
2	El clima no fue lo que esperábamos.
3	Esperábamos el mejor clima, y no fue.

Determinar cuáles de las siguientes representaciones son correctas para el documento 1. Marque con una cruz la/s respuesta/s correcta/s.

el	mejor	clima	fue	no	lo	que	esperábamos	
1	1	1	1	0	0	0	0	Opción a
2	2	2	1	0	0	0	0	Opción b
0.28	0.28	0.28	0.14	0	0	0	0	Opción c

- ¿Qué son las Stop Words? Dar ejemplos.
- ¿Qué es el método Frecuencia de Término-Frecuencia Inversa de Documento (TF-IDF)? ¿Para qué se usa?

OVERFITTING, UNDERFITTING, BIAS Y VARIANZA

Ejercicio: Explique brevemente los conceptos de Overfitting y Underfitting. Mencione cómo puede detectarse cada una de estas situaciones y qué se podría hacer para evitarlas.

Ejercicio: Explique el error de sesgo (Bias) y el Overfitting, y cómo se relacionan con la complejidad de un modelo de aprendizaje automático.

Ejercicio (V/F): Para un proyecto de ciencia de datos, se entrena un modelo predictivo y se evalúa su performance con la métrica F1-Score. Se obtienen los siguientes resultados:

- F1-Score en entrenamiento: 0.25
- F1-Score en test: 0.4

Indique si las siguientes afirmaciones son verdaderas o falsas (V/F):

- a) El modelo generaliza muy bien para datos nuevos. _____ b) El modelo podría estar sobreajustando a los datos de entrenamiento (overfitting). _____ c) Hay un problema en los datos de test, se debería evaluar en otro conjunto. _____ d) El modelo podría estar subajustando a los datos de entrenamiento (underfitting). _____

Ejercicio: ¿Por qué considera que es importante particionar un set de datos en un conjunto de entrenamiento y uno de test respectivamente? ¿Qué consideraciones se deben tener en el preprocesamiento de datos respecto a estos conjuntos?

MÉTRICAS Y VISUALIZACIÓN

Ejercicio (cálculo): Se entrenó un modelo de clasificación (MODELO A) para detectar personas enfermas (clase 1) y sanas (clase 0). Luego se evaluó el modelo en los datos de test y se obtuvo una matriz de confusión. Se pide:

a) Calcular la métrica Precision: _____ b) Calcular la métrica Recall:

c) Se entrenó un segundo modelo de clasificación (MODELO B), se evaluó sobre los mismos datos de test y se obtuvieron los siguientes resultados:

True Positive: 49
True Negative: 130
False Positive: 41
False Negative: 100

¿Qué modelo (A o B) elegiría en términos de Accuracy?: _____

Ejercicio (cálculo, otra variante): Se entrenó un modelo de clasificación para detectar personas sanas (clase 0) y enfermas (clase 1). Se evaluaron dos modelos (Modelo A y Modelo B) obteniendo matrices de confusión con los siguientes valores para la Clase 1:

Modelo A: TP=22, FN=16, FP=12, TN=13
Modelo B: TP=27, FN=11, FP=10, TN=15

a) Calcular F1-Score del Modelo A. b) Calcular F1-Score del Modelo B. c) ¿Qué modelo elegiría en términos de Accuracy? ¿Por qué?

- ¿Qué diferencias hay entre Precisión, Recall y F1?
- ¿Con qué tipo de gráfico podría detectar correlación entre variables?
- ¿En qué consiste la técnica de oversampling y de undersampling?

Ejercicio (V/F): Indique cuáles de las siguientes afirmaciones son verdaderas:

- Cuando dos variables tienen alto índice de correlación significa que existe causalidad (una causa a la otra). _____
- Las variables cuantitativas pueden ser discretas o continuas. _____
- En un problema de clasificación la variable dependiente es cuantitativa. _____
- En un problema de regresión lineal se busca predecir un valor en un rango continuo.

- En un problema de clustering se trata de agrupar los datos en N conjuntos distinguibles, y siempre se sabe qué significan esos conjuntos. _____
-

REDES NEURONALES Y DEEP LEARNING (fundamentos)

Ejercicio: Explique de forma breve: ¿Para qué se utiliza el método backpropagation? ¿Qué tipo de método es, es decir, qué recurso matemático utiliza?

- ¿Qué herramienta matemática usa Backpropagation para disminuir el error durante el entrenamiento?
 - Dibuje de forma sintética el esquema básico de una red convolucional, indicando capas, el orden de estas y las funciones de activación.
 - Explique cada una de las capas de una CNN: capa convolucional, ReLU, Pooling, Fully Connected.
 - ¿Un Perceptrón simple puede resolver problemas que no son linealmente separables?
 - Explicar los 3 tipos de estructuras que puede tener una red recurrente. Dar ejemplos para cada una. ¿Cuál es el principal problema de una red recurrente?
-

REDES PROFUNDAS AVANZADAS (GAN, GRU/LSTM, Autoencoders, Embeddings, Deep Belief)

- ¿Cómo se entrena una red Deep Belief? (*acompañado de 4 afirmaciones V/F sobre Deep Belief Networks cuyo texto exacto no quedó registrado*)
 - Dibuje el esquema de una red GAN indicando el nombre de cada componente.
 - ¿Qué son las redes GAN y cuál es su uso? (incluye diagrama)
 - ¿Qué son las celdas GRU y LSTM?
 - ¿Qué son los Embeddings?
 - ¿Qué es un autoencoder?
-

ÁRBOLES DE DECISIÓN

- ¿Qué modelo utiliza la entropía de la información o el coeficiente de Gini para su entrenamiento?

Ejercicio (V/F): Indicar si las siguientes afirmaciones sobre árboles de decisión son verdaderas o falsas:

a) Un árbol ID3 se construye utilizando la fórmula de entropía de la información, mientras que un árbol C4.5 se construye utilizando la impureza de Gini. _____ b) En un Random

Forest tradicional tengo un bosque de tocones (Stumps). _____ c) Los árboles sólo pueden manejar variables numéricas normalizadas. _____ d) La técnica de poda se utiliza en los árboles C4.5 para evitar el underfitting. _____

ENSAMBLES (Bagging, Boosting, Stacking, Voting, XGBoost)

- Explique la diferencia entre Bagging y Boosting.
 - ¿Qué diferencias hay entre Stacking y Voting?
 - ¿Qué modelos usó para Stacking? Mencione también el metamodelo. ¿Qué resultados arrojó respecto a entrenar los modelos por separado?
 - Mencione dos mecanismos que utiliza XGBoost para reducir el sobreajuste.
 - ¿En qué consiste un ensamble? ¿Qué diferencia hay entre un ensamble híbrido y un ensamble homogéneo?
-

REDUCCIÓN DE DIMENSIONALIDAD

- ¿En qué consiste la reducción de dimensionalidad? ¿Para qué sirve/qué usos tiene?
 - ¿Qué técnica usaría si sabe que los datos están en una variedad del espacio (no linealmente distribuidos)?
 - ¿Qué técnica usaría si desea preservar los clusters?
 - ¿Qué técnica usaría para preservar las distancias entre los puntos?
 - Si quisiera preservar la distancia de Manhattan entre los puntos de un dataset, ¿qué técnica tendría que usar?
 - ¿Qué intenta maximizar en cada componente principal la técnica de PCA?
 - ¿Qué técnica utiliza una distribución Normal y una t-Student para calcular la "similitud" entre puntos?
-

KNN Y SVM

- ¿Qué hace el SVM cuando se enfrenta a un caso que no es linealmente separable?
-

PREPROCESAMIENTO, OUTLIERS Y METODOLOGÍA

- ¿Cómo se analizan los valores atípicos (outliers)? Describir el proceso y cómo se tratan los datos atípicos encontrados.
- ¿En qué consiste la optimización de hiperparámetros? ¿Para qué se utiliza? Dar 2 hiperparámetros de un modelo y describir brevemente.

Ejercicio (V/F): Se tiene un conjunto de datos de 300 filas y 10 columnas y se quiere entrenar un árbol de decisión para resolver un problema de clasificación. Se genera un conjunto de entrenamiento (80%) y un conjunto de test (20%), y se quiere evaluar la performance del modelo en entrenamiento utilizando k-fold cross validation con $k=5$. Determinar si las siguientes afirmaciones son verdaderas o falsas:

a) Habrá 240 registros que estarán 4 veces en un conjunto de entrenamiento y 1 vez en un conjunto de validación. _____ b) Se partirá el conjunto de entrenamiento en 5 subconjuntos, luego cada subconjunto se partirá con proporción 80/20 para entrenar y validar el árbol. _____ c) El árbol de decisión se entrenará 5 veces. _____ d) No se puede utilizar k-fold cross validation para evaluar el entrenamiento, es un método para optimizar hiperparámetros. _____

- ¿Qué técnicas podría usar junto con K-Means para detectar la posible cantidad de clusters en un conjunto de datos?