

Tema 3 — Naive Bayes con Laplace Smoothing

1. ¿QUÉ PROBLEMA RESUELVE?

Clasificación de textos: asignar automáticamente una categoría o tópico a un fragmento de texto. Usos típicos:

- Clasificar un email como "spam" o "no spam"
- Identificar el idioma de un texto
- Identificar el autor, sexo o edad del autor de un texto
- Análisis de sentimientos (positivo/negativo)

Entradas: un documento d , y un conjunto prefijado de clases $C = \{c_1, c_2, \dots, c_j\}$ **Salida:** una clase c perteneciente a C

2. EL RAZONAMIENTO DETRÁS DE NAIVE BAYES

Paso 1: Plantear el problema como probabilidad condicional

La pregunta es: **dado un documento d , ¿cuál es la probabilidad de que pertenezca a la clase c ?** Esto se escribe como $P(c|d)$.

Paso 2: Aplicar el Teorema de Bayes

$$P(c|d) = P(d|c) * P(c) / P(d)$$

Paso 3: Elegir la clase que maximiza esa probabilidad

Si hay varias clases posibles, el documento pertenece a la clase que maximiza $P(c|d)$:

$$C_{\text{map}} = \operatorname{argmax} P(c|d) \quad \text{para } c \in C$$

(C_{map} = "clase máximo a posteriori"; argmax = la función que devuelve el argumento que maximiza la expresión, es decir, LA CLASE, no el valor de la probabilidad en sí)

Paso 4: Simplificar — eliminar el denominador

Como $P(d)$ es la misma para todas las clases (es una constante que no depende de c), se puede eliminar del cálculo sin afectar cuál clase gana:

$$C_{\text{map}} = \operatorname{argmax} P(d|c) * P(c) \quad \text{para } c \in C$$

Esta es LA fórmula central de Naive Bayes. Todo el resto del tema es saber cómo calcular $P(d|c)$ y $P(c)$.

3. ¿CÓMO SE REPRESENTA UN DOCUMENTO? (Bag of Words)

Antes de poder calcular nada, hay que convertir el texto en algo numéricamente manejable.

Modelo Bag of Words (BoW): Representa un documento como una "bolsa de palabras" — un conjunto de características $x_1, x_2, \dots, x_n$, donde cada x_i es una palabra que aparece en el documento.

¿Por qué "bolsa" y no "lista"? Porque NO importa el orden en que aparecen las palabras, ni cuántas veces se repite cada una en el conteo posicional — solo importa qué palabras están presentes. Esto es justamente lo que hace que el modelo sea "ingenuo" (naive).

Armado del vocabulario: Se cuentan todas las palabras únicas que aparecen en TODOS los documentos de entrenamiento. Ese conjunto de palabras únicas es el Vocabulario (V), y $|V|$ es su tamaño (cantidad de palabras distintas).

Tokenización: Antes de armar el vocabulario, hay que separar el texto en palabras individuales (tokens). Normalmente se separan los caracteres alfabéticos de los signos de puntuación, espacios, etc.

4. EL SUPUESTO "INGENUO" (NAIVE) DE INDEPENDENCIA

Como calcular $P(d|c)$ directamente es muy difícil (habría que conocer la probabilidad conjunta de todas las palabras apareciendo juntas), Naive Bayes hace una simplificación:

Supone que todas las palabras del documento son independientes entre sí, y que el orden no importa.

Esto permite descomponer:

$$P(d|c) = P(x_1, x_2, x_3, \dots, x_n | c) = P(x_1|c) * P(x_2|c) * P(x_3|c) * \dots * P(x_n|c)$$

Es decir, la probabilidad de todo el documento dado la clase es simplemente el PRODUCTO de las probabilidades de cada palabra individual dado la clase.

¿Por qué se llama "ingenuo"? Porque en la realidad las palabras SÍ tienen relación entre sí (el orden y el contexto importan). Por ejemplo:

■ "Él es una buena persona y no un violento" $\neq$ "Él es un violento y no una buena persona"

Para Naive Bayes, estas dos oraciones tendrían la MISMA representación (mismas palabras), aunque signifiquen cosas opuestas. A pesar de esta simplificación excesiva, en la práctica el modelo funciona sorprendentemente bien.

La fórmula final combinando todo:

$$C_{\text{map}} = \operatorname{argmax} P(c_j) * \prod P(x_i | c_j) \quad \text{para } c_j \in C, i \in \text{posiciones del documento}$$

($\prod$ significa productoria: multiplicar todos los términos)

5. CÓMO CALCULAR $P(c)$ — probabilidad de la clase

Es simplemente qué proporción de los documentos de entrenamiento pertenece a esa clase:

$$P(c) = \text{cantidad de documentos de clase } c / \text{cantidad total de documentos}$$

Este es un valor que estimamos a partir del conjunto de entrenamiento T (no lo "conocemos" de antemano, lo estimamos con los datos que tenemos).

6. CÓMO CALCULAR $P(w_i | c)$ — probabilidad de una palabra dada la clase

$$P(w_i | c) = \frac{\text{cantidad de veces que aparece } w_i \text{ en documentos de clase } c}{\text{cantidad total de palabras en documentos de clase } c}$$

Importante: el denominador es la SUMA de todas las palabras (contando repeticiones) en los documentos de esa clase — no la cantidad de palabras ÚNICAS.

El problema: palabras nunca vistas

Si una palabra del documento de prueba nunca apareció en el conjunto de entrenamiento para una clase determinada, su probabilidad da CERO. Y como las probabilidades se MULTIPLICAN entre sí, un solo cero hace que TODA la probabilidad del documento para esa clase sea cero, sin importar qué tan bien encajen las demás palabras.

Acá es donde entra Laplace Smoothing.

7. LAPLACE SMOOTHING (Add-One Smoothing)

¿Qué es? Una técnica esencial para evitar que palabras no vistas en el entrenamiento asignen una probabilidad de cero a toda una clase.

¿Cómo funciona? Se suma 1 al conteo de cada palabra (en el numerador), y se suma el tamaño del vocabulario $|V|$ al denominador, para "compensar" matemáticamente ese +1 que se sumó por cada palabra posible.

La fórmula CON Laplace Smoothing:

$$P'(w_i | c_j) = \frac{[cantidad(w_i, c_j) + 1]}{[\sum_{w \in V} cantidad(w, c_j)] + |V|}$$

Donde:

- $cantidad(w_i, c_j)$ = veces que aparece la palabra w_i en documentos de clase c_j
- $\sum cantidad(w, c_j)$ = suma total de todas las palabras (con repetición) en documentos de clase c_j
- $|V|$ = tamaño del vocabulario (cantidad de palabras únicas en TODO el conjunto de entrenamiento, incluyendo palabras de otras clases)

Punto clave que se pregunta seguido: $|V|$ se calcula sobre TODO el vocabulario del conjunto de entrenamiento (todas las clases juntas), no solo sobre las palabras de la clase que estás evaluando en ese momento.

8. RESOLUCIÓN PASO A PASO — EJEMPLO COMPLETO

Este es el formato EXACTO que usan en los exámenes. Vamos a resolver el ejercicio real que salió en el Final del 13-12-2022 y en varios simulacros.

Enunciado tipo:

Documento	Palabras	Clase
1	Star Wars	A
2	Star Wars Game	A
3	Star Trek	B
4	Star estrella	? (documento de prueba)

Calcule, usando Laplace Smoothing: a) Vocabulario b) $P(\text{Clase A})$ c) $P(\text{Clase B})$ d) $P(\text{"estrella"} | \text{Clase A})$

Resolución:

a) Vocabulario

Se toman todas las palabras ÚNICAS que aparecen en TODOS los documentos de ENTRENAMIENTO (documentos 1, 2 y 3 — el documento 4 es el de prueba, NO se usa para construir el vocabulario, salvo que el enunciado diga lo contrario):

Palabras en doc 1: Star, Wars
Palabras en doc 2: Star, Wars, Game
Palabras en doc 3: Star, Trek

Vocabulario = { Star, Wars, Game, Trek }
 $|V| = 4$

Nota importante: Algunos exámenes SÍ piden incluir las palabras del documento de prueba en el vocabulario (revisar bien el enunciado). En este caso, "estrella" es una palabra nueva que solo aparece en el documento de prueba, así que si el enunciado lo pide incluir:

Vocabulario = { Star, Wars, Game, Trek, estrella }
 $|V| = 5$

Para este ejercicio, vamos a seguir con $|V| = 4$ (sin incluir "estrella", criterio más común salvo indicación contraria).

b) P(Clase A)

$P(A) = \text{documentos de clase A} / \text{documentos totales de entrenamiento}$
 $= 2 / 3$

(Hay 2 documentos de clase A —doc 1 y doc 2— de un total de 3 documentos de entrenamiento)

c) P(Clase B)

$P(B) = \text{documentos de clase B} / \text{documentos totales de entrenamiento}$
 $= 1 / 3$

d) P("estrella" | Clase A) — con Laplace Smoothing

Primero, contamos cuántas veces aparece "estrella" en los documentos de clase A: **0 veces** (nunca aparece en los documentos de entrenamiento de clase A — es una palabra nueva).

Contamos el total de palabras (con repetición) en los documentos de clase A:

Doc 1 (Star Wars): 2 palabras
Doc 2 (Star Wars Game): 3 palabras
Total en clase A: $2 + 3 = 5$ palabras

Aplicamos Laplace Smoothing:

$$\begin{aligned}
 P(\text{"estrella"} \mid A) &= (\text{cantidad}(\text{"estrella"}, A) + 1) / (\text{total_palabras_A} + |V|) \\
 &= (0 + 1) / (5 + 4) \\
 &= 1 / 9
 \end{aligned}$$

Sin Laplace Smoothing, esta probabilidad hubiera sido $0/5 = 0$, lo cual arruinaría todo el cálculo de clasificación. Por eso es indispensable.

9. CLASIFICAR EL DOCUMENTO DE PRUEBA (paso extra que a veces piden)

Si el ejercicio pide clasificar el documento 4 ("Star estrella"), hay que calcular $P(A|d)$ y $P(B|d)$ usando la fórmula completa y comparar cuál es mayor.

$$C_{\text{map}} = \operatorname{argmax} P(c_j) * \prod P(\text{palabra}_i \mid c_j)$$

Para clase A:

$$P(A) * P(\text{Star}|A) * P(\text{estrella}|A)$$

Necesitamos $P(\text{Star}|A)$ con Laplace:

$$\begin{aligned}
 &\text{"Star"} \text{ aparece 2 veces en clase A (una vez en doc1, una vez en doc2)} \\
 P(\text{Star}|A) &= (2+1) / (5+4) = 3/9 = 1/3
 \end{aligned}$$

$$\begin{aligned}
 \text{Score_A} &= P(A) * P(\text{Star}|A) * P(\text{estrella}|A) \\
 &= (2/3) * (1/3) * (1/9) \\
 &= 2/81
 \end{aligned}$$

Para clase B:

$$\begin{aligned}
 &\text{Total de palabras en clase B: doc3 "Star Trek" = 2 palabras} \\
 &\text{"Star"} \text{ aparece 1 vez en clase B} \rightarrow P(\text{Star}|B) = (1+1)/(2+4) = 2/6 = 1/3 \\
 &\text{"estrella"} \text{ aparece 0 veces en clase B} \rightarrow P(\text{estrella}|B) = (0+1)/(2+4) = 1/6
 \end{aligned}$$

$$\begin{aligned}
 \text{Score_B} &= P(B) * P(\text{Star}|B) * P(\text{estrella}|B) \\
 &= (1/3) * (1/3) * (1/6) \\
 &= 1/54
 \end{aligned}$$

Comparación:

$$\text{Score_A} = 2/81 \approx 0.0247$$

$$\text{Score_B} = 1/54 \approx 0.0185$$

Como $\text{Score_A} > \text{Score_B} \rightarrow$ **el documento se clasifica como Clase A.**

Importante: estos "scores" NO son probabilidades reales (no suman 1), porque eliminamos el denominador $P(d)$ de la fórmula original. Solo sirven para COMPARAR cuál clase es más probable — el que da mayor valor gana.

10. OTRO EJEMPLO REAL DE EXAMEN (para practicar la variante V/F)

Este formato salió en un ejemplo de parcial real:

Documento	Palabras en el documento	Clase
1 (entrenamiento)	Hola Chau	Clase A
2 (entrenamiento)	Chau Chau Chau	Clase B
3 (prueba)	desfibrilador	???

Pregunta: ¿Cuál es $P(\text{"desfibrilador"} \mid \text{Clase A})$ con Laplace Smoothing?

Resolución:

Vocabulario (de los documentos de entrenamiento 1 y 2):

$$V = \{ \text{Hola, Chau} \}$$
$$|V| = 2$$

Total de palabras en clase A (doc 1: "Hola Chau"): 2 palabras

"desfibrilador" aparece 0 veces en clase A (nunca se vio esa palabra)

$$P(\text{desfibrilador} \mid A) = (0 + 1) / (2 + 2) = 1/4 = 0.25$$

Respuesta correcta: 0.2 (la opción del examen real). Esto puede variar levemente según cómo se arme el vocabulario exacto en el enunciado — el punto es dominar el mecanismo del cálculo, no memorizar un resultado.

11. TÉCNICAS PARA MEJORAR EL RENDIMIENTO DEL MODELO (Feature Engineering en texto)

Estas técnicas se aplican sobre el Bag of Words antes de entrenar, mejorando la calidad de la representación:

- **Normalización:** pasar todas las palabras a minúsculas, sin tildes, sin caracteres especiales.
 - **Stop Words:** eliminar palabras muy frecuentes que no aportan significado semántico (el, y, un, de, la).
 - **TF-IDF (Term Frequency - Inverse Document Frequency):** en vez de contar simplemente cuántas veces aparece una palabra, asigna un peso según su frecuencia en el documento (TF) y su rareza en el corpus completo (IDF). Esto le da más peso a palabras representativas y menos a palabras muy comunes que aparecen en todos los documentos.
 - **N-gramas:** en vez de tomar palabras aisladas, se toman secuencias de N palabras consecutivas. Esto recupera algo de información de orden que Bag of Words pierde.
 - **Stemming:** elimina sufijos de las palabras (en inglés, "ing", "ed"). Por ejemplo: "running" → "run".
 - **Lematización:** lleva las palabras a su forma canónica o base (el lema). Por ejemplo: "corriendo", "corrió", "corre" → "correr".
-

12. REDES BAYESIANAS (para diferenciar de Naive Bayes)

Un tema relacionado que a veces se pregunta para contrastar con Naive Bayes.

¿Qué son? Un grafo acíclico dirigido donde:

- Los nodos representan variables
- Las aristas representan dependencias condicionales entre esas variables
- Cada nodo tiene asociada una tabla de probabilidades condicionales

Diferencia clave con Naive Bayes: Naive Bayes asume que TODAS las palabras/variables son independientes entre sí (dado la clase). Las Redes Bayesianas, en cambio, permiten modelar dependencias explícitas entre variables — no todo depende solo de la clase, sino que las variables pueden depender unas de otras.

Permiten hacer inferencia: dado que se observaron ciertos eventos, se puede calcular la probabilidad de otro evento. Por ejemplo: si sabemos que "Juan llama" = true y "María llama" = true, ¿cuál es la probabilidad de que haya habido un robo?

Trade-off:

- Redes Bayesianas → inferencias mucho más precisas, PERO son complejas de construir y mantener
- Naive Bayes → menos preciso (por el supuesto ingenuo), PERO es muy rápido, requiere poco almacenamiento, es robusto ante palabras irrelevantes, y funciona muy bien cuando hay muchas palabras relevantes. Si el supuesto de independencia fuera cierto, sería óptimo.

PREGUNTAS DE PRÁCTICA (formato final real)

Pregunta 1 (Cálculo — formato real de examen)

Suponga que tiene el siguiente conjunto de datos, y debe realizar una tarea de procesamiento de lenguaje natural con Bayes Naive:

Documento	Palabras	Clase
1	Star Wars	A
2	Star Wars Game	A
3	Star Trek	B
4	Star estrella	?

Calcule los siguientes valores, asumiendo Laplace Smoothing (puede dejar las fracciones indicadas):

a) Vocabulario b) $P(\text{Clase A})$ c) $P(\text{Clase B})$ d) $P(\text{"estrella"} \mid \text{Clase A})$

Pregunta 2 (Cálculo — formato real de examen, otro dataset)

Dado el siguiente conjunto de datos:

Documento	Palabras	Clase
1	buena	POS
2	horrenda	NEG
3	buena estrella	POS
4	estrella horrenda	?

Calcule con Laplace Smoothing: a) $|\text{Vocabulario}|$ b) $P(\text{Clase POS})$ c) $P(\text{Clase NEG})$ d) $P(\text{"estrella"} \mid \text{POS})$

Pregunta 3 (Desarrollo)

Explique qué es el Laplace Smoothing y por qué es necesario en Naive Bayes.

Pregunta 4 (Desarrollo)

¿Por qué se dice que Naive Bayes es un clasificador "ingenuo"? ¿Qué supuesto hace y por qué puede no ser realista?

Pregunta 5 (V/F)

- a) El denominador $P(d)$ se elimina del cálculo de Naive Bayes porque es igual a cero.
- b) $|V|$ (tamaño del vocabulario) se calcula únicamente sobre las palabras que aparecen en la clase que se está evaluando.

c) Sin Laplace Smoothing, una palabra nunca vista en el entrenamiento haría que la probabilidad de todo el documento para esa clase sea cero.

d) Las Redes Bayesianas son más simples de construir y mantener que Naive Bayes.

RESPUESTAS MODELO

Respuesta 1

a) **Vocabulario** (de los documentos de entrenamiento 1, 2 y 3):

$V = \{ \text{Star, Wars, Game, Trek} \}$
 $|V| = 4$

b) **P(Clase A)** = 2/3 (2 documentos de clase A de 3 totales)

c) **P(Clase B)** = 1/3 (1 documento de clase B de 3 totales)

d) **P("estrella" | Clase A):**

Total de palabras en clase A = 5 (2 en doc1 + 3 en doc2)
"estrella" aparece 0 veces en clase A
 $P(\text{"estrella"}|A) = (0+1) / (5+4) = 1/9$

Respuesta 2

a) **Vocabulario** (de docs 1, 2, 3):

$V = \{ \text{buena, horrenda, estrella} \}$
 $|V| = 3$

b) **P(POS)** = 2/3 (docs 1 y 3 son POS, de 3 totales)

c) **P(NEG)** = 1/3 (doc 2 es NEG, de 3 totales)

d) **P("estrella" | POS):**

Total de palabras en POS = 3 (1 en doc1 "buena" + 2 en doc3 "buena estrella")
"estrella" aparece 1 vez en POS (en doc3)
 $P(\text{"estrella"}|POS) = (1+1) / (3+3) = 2/6 = 1/3$

Respuesta 3

Laplace Smoothing (o Add-One Smoothing) es una técnica esencial para evitar que palabras no vistas en el conjunto de entrenamiento asignen una probabilidad de cero a toda la clase. Como las probabilidades de las palabras se multiplican entre sí para calcular $P(d|c)$,

si una sola palabra tiene probabilidad cero, todo el producto se vuelve cero, sin importar qué tan bien encajen las demás palabras del documento con esa clase. La técnica consiste en sumar 1 al conteo de cada palabra en el numerador, y sumar el tamaño del vocabulario $|V|$ al denominador, garantizando que ninguna palabra tenga probabilidad exactamente cero.

Respuesta 4

Se llama "ingenuo" (naive) porque asume que todas las palabras del documento son estadísticamente independientes entre sí dado la clase, y que el orden en el que aparecen no importa. Esto simplifica enormemente el cálculo (permite descomponer $P(d|c)$ como un simple producto de probabilidades individuales), pero no es realista: en el lenguaje natural las palabras sí tienen relaciones de dependencia y el orden cambia el significado. Por ejemplo, "él es una buena persona y no un violento" y "él es un violento y no una buena persona" tendrían la misma representación para Naive Bayes, aunque signifiquen cosas opuestas. A pesar de esta simplificación, el modelo funciona sorprendentemente bien en la práctica, especialmente cuando hay muchas palabras relevantes.

Respuesta 5

a) **FALSO.** $P(d)$ se elimina porque es una constante que no depende de la clase c (es la misma para todas las clases al comparar), no porque sea cero. Al no depender de c , no afecta cuál clase maximiza la expresión, por lo que se puede quitar sin cambiar el resultado.

b) **FALSO.** $|V|$ se calcula sobre TODO el vocabulario del conjunto de entrenamiento, considerando todas las clases juntas, no solo las palabras de la clase que se está evaluando en ese momento.

c) **VERDADERO.** Como las probabilidades de las palabras se multiplican entre sí, una probabilidad de cero (por una palabra nunca vista) hace que el producto completo sea cero, arruinando la clasificación para esa clase.

d) **FALSO.** Es al revés: las Redes Bayesianas son MÁS complejas de construir y mantener que Naive Bayes, aunque permiten inferencias más precisas al modelar dependencias explícitas entre variables.