

Tema 5 — Reducción de Dimensionalidad (PCA, MDS, t-SNE, ISOMAP)

1. ¿PARA QUÉ SIRVE LA REDUCCIÓN DE DIMENSIONALIDAD?

Permite visualizar datos que tienen muchas variables (dimensiones) en un espacio más chico (típicamente 2D o 3D), preservando características importantes de los datos originales: distancias, correlaciones, estructura.

Usos:

- Visualización de datos para entender su distribución
- Detección de patrones/agrupamientos a simple vista
- Reducción del ruido
- Aceleración de los tiempos de entrenamiento de otros modelos (menos dimensiones = menos cómputo)

Algoritmos que existen: PCA, ISOMAP, LLE, Proyecciones aleatorias, MDS, t-SNE, LDA, UMAP. Los que se ven en la materia (y los que hay que dominar): **PCA, MDS, t-SNE, ISOMAP.**

2. PCA (Análisis de Componentes Principales)

La idea central

PCA busca los ejes (llamados "componentes principales") que capturan la mayor cantidad de variación/dispersión posible en los datos, permitiendo representar datos de muchas dimensiones en menos dimensiones sin perder demasiada información.

El proceso paso a paso

Paso 1: Centrar los datos

Se calcula el promedio de cada variable, y se calcula el "centro" del conjunto de datos (el punto formado por esos promedios). Se centran los datos en ese punto (se corren todos los ejes para que el centro quede en el origen de coordenadas).

Paso 2: Encontrar la recta que mejor ajusta (PC1)

Se traza una línea que pasa por el origen y se la rota hasta que ajuste lo mejor posible a la nube de puntos — de forma similar a la regresión lineal por cuadrados mínimos, pero con una diferencia importante en qué se minimiza/maximiza.

¿Cómo se define "mejor ajuste" en PCA?

Por el Teorema de Pitágoras, para cada punto: $a^2 = b^2 + c^2$, donde:

- a = distancia del punto al origen (esto NO cambia sin importar cómo rotemos la recta)
- b = distancia perpendicular del punto a la recta
- c = distancia desde el origen hasta la proyección del punto sobre la recta

Como a es constante, minimizar b (la distancia del punto a la recta) es matemáticamente equivalente a maximizar c (la distancia desde el origen hasta la proyección).

PCA maximiza la suma de las distancias al cuadrado (c^2) de los puntos proyectados sobre la recta, medidas desde el origen. Esto es equivalente a decir que maximiza la varianza de los datos proyectados.

Se maximiza: $d_1^2 + d_2^2 + d_3^2 + \dots + d_n^2$
(donde d_i es la distancia desde el origen hasta la proyección del punto i)

Paso 3: Esa recta es PC1 (Primera Componente Principal)

Ejemplo concreto (de las diapos): si la pendiente de PC1 es 0,25, significa que cada 4 unidades que avanzas en un eje (por ejemplo "árboles"), te movés 1 unidad en el otro eje ("RNA"). Esto indica que los datos están mucho más dispersos en el eje "árboles" que en "RNA".

Como PC1 es una combinación de ambos ejes originales (en una proporción específica), se dice que es una **combinación lineal de variables**.

Loading Scores y Autovalores

Usando SVD (Singular Value Decomposition), se normaliza el vector de PC1 (se divide por su longitud). Las proporciones resultantes de cada eje original se llaman **Loading Scores** — indican cuánto "pesa" cada variable original en esa componente principal.

Las distancias al cuadrado sumadas (la cantidad que PCA maximizó) se llaman **autovalores** de esa componente principal.

PC2 (Segunda Componente Principal)

En un espacio 2D, solo hay una posibilidad: PC2 es la única recta que pasa por el origen y es **perpendicular** a PC1. Se normaliza de la misma forma (obteniendo su propio autovector).

En 3D, para encontrar PC2 hay varias posibilidades: se busca la que pasa por el origen, es perpendicular a PC1, Y maximiza su propio autovector (varianza). PC3 luego debe ser perpendicular a las otras dos.

Variación explicada por cada componente

Variación de PCn = (Suma de distancias cuadradas de PCn) / (n-1)

Ejemplo con 3 variables (de las diapos):

PC1: 79% de la variación

PC2: 15% de la variación

PC3: 6% de la variación

PC1 + PC2 = 94% de la variación total

Como PC1 y PC2 juntos capturan el 94%, graficar solo esas dos dimensiones (en vez de las 3 originales) es una muy buena aproximación de los datos reales, y permite visualizarlos en 2D sin perder casi información.

Scree Plot

Es el gráfico donde se representa el porcentaje de variación explicada por cada componente principal. Sirve para decidir cuántas componentes conservar: si las primeras 2 o 3 explican la gran mayoría de la variación, con esas alcanza para tener una buena representación reducida.

Si el Scree Plot muestra que ninguna componente concentra mucha variación (por ejemplo, PC1=30%, PC2=20%, y el resto repartido), usar solo PC1 y PC2 no va a representar bien la dispersión real de los datos — aunque igual puede servir para detectar agrupamientos aproximados.

Para qué sirve PCA en definitiva

Identificar si hay agrupamiento de datos en el espacio de entrada, detectar correlaciones, clusters, y entender cuán dispersos están los datos y sobre qué variables. Es especialmente útil cuando no se puede representar visualmente el espacio original por tener demasiadas dimensiones.

3. MDS (Multidimensional Scaling) y PCoA

Classical MDS es exactamente igual a PCoA (Principal Coordinate Analysis) — son el mismo método con dos nombres distintos según el área.

La idea central

A diferencia de PCA (que maximiza varianza/correlación), MDS busca **preservar las distancias entre los puntos**. Ubica los puntos en una dimensión menor de forma tal que las distancias entre ellos se parezcan lo más posible a las distancias originales.

El proceso paso a paso

Paso 1: Calcular la distancia entre cada par de puntos en el espacio original (puede ser distancia euclidiana u otra). Esto arma una **matriz de distancias**.

Paso 2: Se necesita encontrar una nueva matriz con la misma cantidad de columnas (ejemplos) pero MENOS filas (menos dimensiones — las que se quieran para visualizar, por ejemplo 2). Para esa nueva matriz reducida, se calculan también las distancias entre puntos, generando una **segunda matriz de distancias**, que debería parecerse lo más posible a la primera.

Paso 3: Función de Stress

Se define una función llamada **Stress**, que mide qué tan distintas son las distancias del espacio reducido respecto de las distancias originales. El objetivo es **minimizar** esta función de Stress. Si el Stress es 0, las distancias son idénticas (proyección perfecta).

Paso 4: Resolver con descenso por gradiente

Para encontrar los valores que minimizan el Stress se usan algoritmos como el descenso por gradiente (Kruskal's steepest descent method, entre otros). Es la misma técnica de optimización usada en regresión lineal, PCA y backpropagation: encontrar el mínimo de una función moviéndose iterativamente en la dirección que más reduce el error.

Mecánica del descenso por gradiente aplicado a MDS:

- 1. Se colocan los puntos en posiciones aleatorias en el nuevo espacio reducido
- 2. Se calcula el error (Stress) actual
- 3. Se calcula la derivada (gradiente) del error respecto a cada coordenada
- 4. Se actualiza cada coordenada moviéndola un poco en la dirección que reduce el error, según una tasa de aprendizaje (learning rate)
- 5. Se repite iterativamente hasta que el error converge a un mínimo

Distancias alternativas

No hace falta usar solamente distancia euclidiana. Se puede usar cualquier medida de distancia apropiada al problema, por ejemplo **Hamming Distance** (mide el número mínimo de sustituciones necesarias para cambiar una cadena en otra).

MDS vs PCA

	PCA	MDS / PCoA
Qué preserva	Correlación entre ejemplos	Distancia entre ejemplos
Método	Descomposición en autovectores/autovalores	Optimización iterativa (minimizar Stress)

Dato importante: minimizar las distancias lineales entre puntos (como hace MDS) es matemáticamente equivalente a maximizar la correlación lineal (como hace PCA) — por

eso, usando distancia euclidiana, ambos métodos suelen dar resultados muy similares o idénticos.

Fortalezas y debilidades de MDS

Fortalezas:

- Soporta varios tipos de distancias
- Permite transformaciones no lineales

Debilidades:

- Optimización iterativa con riesgo de mínimos locales
 - Es difícil determinar qué distancia es la mejor para cada problema
-

4. t-SNE (t-distributed Stochastic Neighbor Embedding)

Desarrollado en 2008 por Geoffrey Hinton y Laurens Van Der Maaten. Al igual que PCA, toma datos de un espacio de alta dimensión y los proyecta en un espacio de menor dimensión.

La idea central

t-SNE está diseñado específicamente para **preservar los clusters** — prioriza que los puntos que están cerca en el espacio original queden cerca en la proyección reducida, y que los que están lejos queden lejos.

Cómo funciona (intuición: imanes y repulsión)

Empieza colocando los puntos en el espacio reducido (por ejemplo, en una línea o en 2D) en orden ALEATORIO. Luego va moviendo los puntos uno por uno, en pasos secuenciales: los puntos que pertenecen al mismo cluster "atraen" (como imanes) al punto que se está moviendo, mientras que los puntos que están lejos en el espacio original lo "repelen".

Mecanismo interno paso a paso

Paso 1: Calcular similitud en el espacio original

Para cada punto, se mide la distancia a todos los demás puntos, y esa distancia se proyecta sobre una curva Normal (campana de Gauss) centrada en el punto de interés. Esto da un valor de **similitud** (no escalada).

Importante: el ancho de la curva Normal (su desvío estándar) NO es igual para todos los puntos — depende de la densidad de datos cerca de cada punto. Zonas más densas → curva más angosta. Zonas menos densas → curva más ancha.

Este ancho se controla con un parámetro llamado **perplejidad** (perplexity), que representa la densidad esperada para un punto.

Paso 2: Normalizar (calcular los scores)

$$\text{Score} = \text{Similitud} / (\text{Suma de todas las similitudes})$$

Al final se obtiene una **matriz de puntajes de similitud** (Similarity Scores) en el espacio original.

Paso 3: Calcular similitud en el nuevo espacio (reducido)

Se proyectan los puntos aleatoriamente en el espacio reducido, y se calcula la similitud entre ellos ahí también — pero en vez de usar una distribución Normal, se usa una **distribución t de Student**.

¿Por qué t de Student y no Normal? (esto es la "t" de t-SNE)

La distribución t es un poco más baja en el centro y más alta en los extremos que la Normal. Esto permite que los puntos en el espacio reducido aparezcan un poco más "dispersos", ayudando a una mejor visualización y evitando que todos los puntos se amontonen en el centro.

Paso 4: Ajustar iterativamente

El objetivo es que la matriz de similitud del espacio reducido se parezca lo más posible a la matriz de similitud del espacio original. Como no se puede calcular de una sola vez, se hace en pequeños pasos, moviendo los puntos uno por uno hasta que las matrices coincidan lo mejor posible.

t-SNE vs PCA

En un ejemplo con el dataset MNIST: PCA tardó 0.03 segundos, t-SNE tardó 9 segundos — t-SNE es mucho más lento, pero suele dar mejores resultados de visualización, especialmente para preservar clusters no lineales.

Fortalezas y debilidades de t-SNE

Fortalezas:

- De los mejores métodos para visualizar datos
- Conserva estructuras no lineales, tanto globales como locales

Debilidades:

- Es estocástico (no determinista — cada corrida puede dar un resultado ligeramente distinto)
 - Escala mal en tiempo con la cantidad de dimensiones y puntos (es lento)
 - No se puede usar directamente para proyectar NUEVOS puntos (hay que re-ejecutar todo el algoritmo con el dataset completo)
-

El problema que resuelve

PCA (y otros métodos lineales) usan la distancia **euclidiana**, que mide la línea recta entre dos puntos. Pero si los datos siguen una estructura curva (una "variedad" o manifold), la distancia euclidiana puede ser engañosa.

Hipótesis de variedades (Manifold Hypothesis): la mayoría de los conjuntos de datos de alta dimensión del mundo real quedan cerca de una variedad (superficie) de muchas menos dimensiones. Este supuesto se observa empíricamente en la práctica (ej: MNIST tiene 784 dimensiones de entrada, pero los dígitos reales ocupan una variedad de muchas menos dimensiones dentro de ese espacio).

Ejemplo clásico: si los datos forman una "S" en el espacio, dos puntos pueden estar geométricamente cerca en línea recta (distancia euclidiana chica) pero estar muy lejos si seguís el camino a lo largo de la forma de "S" (la topología real de los datos).

La solución: Distancia Geodésica

En vez de usar distancia euclidiana (línea recta), ISOMAP usa **distancia geodésica**: la línea de mínima longitud que une dos puntos **siguiendo la superficie** en la que están distribuidos los datos (no atravesándola en línea recta).

Cómo funciona ISOMAP paso a paso

Paso 1: Construir un grafo pesado

Para cada punto, se toman sus **K vecinos más cercanos** (usando distancia euclidiana para esto — K es un hiperparámetro del método). Se trazan aristas (conexiones) entre cada punto y sus K vecinos, ponderadas según la distancia euclidiana entre ellos.

Paso 2: Aproximar la distancia geodésica

Se construye una matriz de distancias, pero en vez de usar la distancia euclidiana directa entre dos puntos cualquiera, se calcula el camino más corto a través del grafo (siguiendo las aristas conectadas) — esto aproxima la distancia geodésica real siguiendo la forma de los datos.

Paso 3: Aplicar MDS

Una vez que se tiene la matriz de distancias geodésicas aproximadas, se aplica MDS sobre esa matriz para proyectar los puntos en un espacio de menor dimensión, preservando esas distancias geodésicas.

Limitaciones de ISOMAP

- Es un algoritmo **lento**: a partir de aproximadamente 1000 observaciones, la lentitud se vuelve notoria
- Puede generar una proyección errónea si K es demasiado grande respecto de la estructura de la variedad, o si hay ruido en los datos (puntos ligeramente desplazados)

fuera de la variedad real) — incluso un solo dato mal medido puede alterar significativamente el resultado

Landmark ISOMAP (variante más eficiente)

Para acelerar el algoritmo con datasets grandes: se eligen N puntos "especiales" (landmarks), con N menor que el total de datos (elegidos de forma uniformemente distribuida). Solo se calculan las distancias que involucran a estos N puntos especiales, y luego se aplica **Landmark-MDS (LMDS)** sobre esa matriz de distancias reducida para encontrar la proyección de TODOS los puntos.

6. TABLA COMPARATIVA GENERAL

Método	Qué preserva	Tipo de relación	Velocidad	Usa para nuevos puntos
PCA	Varianza / correlación	Lineal	Rápido	Sí
MDS / PCoA	Distancias entre puntos	Lineal (con euclidiana) o no lineal (con otras distancias)	Medio (iterativo)	Depende del método
t-SNE	Clusters / vecindad local	No lineal	Lento	No
ISOMAP	Distancia geodésica (forma de la variedad)	No lineal	Lento	No directamente

¿Cuándo usar cada uno?

- **PCA:** primera opción rápida, cuando la estructura es aproximadamente lineal, o para tener una primera idea general de la dispersión
 - **MDS:** cuando importa preservar distancias específicas, y se puede elegir la métrica de distancia más apropiada al problema
 - **t-SNE:** cuando el objetivo es visualizar clusters claramente, aunque sea costoso computacionalmente
 - **ISOMAP:** cuando los datos siguen una estructura curva/no lineal (una variedad) y la distancia euclidiana directa sería engañosa
-

Pregunta 1 (Desarrollo)

Explique qué es un Scree Plot y para qué se utiliza en PCA.

Pregunta 2 (Desarrollo)

¿Cuál es la diferencia fundamental entre lo que preserva PCA y lo que preserva MDS?

Pregunta 3 (Desarrollo)

Un conjunto de datos tiene la forma de una "S" en el espacio. ¿Por qué PCA podría dar una mala representación de estos datos? ¿Qué método usaría en su lugar y por qué?

Pregunta 4 (V/F)

- a) t-SNE es determinista: siempre da el mismo resultado si se corre varias veces con los mismos datos.
- b) ISOMAP usa distancia geodésica en vez de distancia euclidiana directa.
- c) MDS y PCA, usando distancia euclidiana, suelen dar resultados similares porque minimizar distancias es equivalente a maximizar la correlación lineal.
- d) t-SNE puede usarse directamente para proyectar nuevos puntos sin volver a correr el algoritmo completo.

Pregunta 5 (Desarrollo)

Explique brevemente qué es la Hipótesis de Variedades (Manifold Hypothesis) y cómo se relaciona con ISOMAP.

RESPUESTAS MODELO

Respuesta 1

El Scree Plot es un gráfico que representa el porcentaje de variación explicada por cada componente principal (PC1, PC2, PC3, etc.) de un análisis PCA. Se usa para decidir cuántas componentes conservar al reducir la dimensionalidad: si las primeras 2 o 3 componentes concentran la mayor parte de la variación total (por ejemplo, $PC1 + PC2 = 94\%$), se puede representar el dataset en 2D o 3D sin perder demasiada información. Si, en cambio, la variación está muy repartida entre muchas componentes, una proyección de solo 2 dimensiones no representará bien la dispersión real de los datos.

Respuesta 2

PCA busca maximizar la varianza (o, equivalentemente, la correlación lineal) de los datos proyectados sobre nuevos ejes (las componentes principales). MDS, en cambio, busca preservar las DISTANCIAS entre los puntos: ubica los puntos en el espacio reducido de

forma que las distancias entre ellos se parezcan lo más posible a las distancias en el espacio original. Usando distancia euclidiana, ambos enfoques suelen llegar a resultados equivalentes, porque minimizar distancias es matemáticamente equivalente a maximizar la correlación lineal.

Respuesta 3

PCA usa distancia euclidiana (línea recta) para encontrar los ejes de mayor varianza. En una estructura con forma de "S", dos puntos pueden estar cerca en línea recta pero muy lejos si se sigue la forma real de los datos (su topología). PCA no tiene en cuenta esa curvatura, por lo que podría agrupar como "cercaños" puntos que en realidad están en extremos opuestos de la "S", dando una representación distorsionada.

En su lugar usaría **ISOMAP**, porque calcula la distancia GEODÉSICA (siguiendo la superficie de los datos, no en línea recta), lo que permite capturar correctamente la verdadera estructura no lineal de los datos.

Respuesta 4

a) **FALSO**. t-SNE es estocástico (no determinista) — distintas corridas con los mismos datos pueden dar resultados ligeramente distintos, porque parte de una inicialización aleatoria de los puntos.

b) **VERDADERO**. ISOMAP construye un grafo de vecinos cercanos y aproxima la distancia geodésica calculando el camino más corto a través del grafo, en vez de usar la distancia euclidiana directa entre dos puntos cualquiera.

c) **VERDADERO**. Minimizar las distancias lineales entre puntos (como hace MDS) es matemáticamente equivalente a maximizar la correlación lineal (como hace PCA), por lo que usando distancia euclidiana ambos métodos tienden a converger a resultados similares.

d) **FALSO**. Es una de las debilidades de t-SNE: no se puede usar directamente para proyectar nuevos puntos; hay que volver a correr el algoritmo completo con el dataset ampliado.

Respuesta 5

La Hipótesis de Variedades sostiene que la mayoría de los conjuntos de datos de alta dimensión del mundo real quedan cerca de una variedad (manifold) de muchas menos dimensiones dentro de ese espacio de alta dimensión. Por ejemplo, el dataset MNIST tiene imágenes de 784 dimensiones (28x28 píxeles), pero los dígitos reales ocupan una variedad de muchas menos dimensiones dentro de ese espacio.

Esta hipótesis es la base conceptual de ISOMAP: si los datos realmente siguen una variedad de menor dimensión, entonces la distancia geodésica (siguiendo esa variedad) es una medida más fiel de la verdadera cercanía entre puntos que la distancia euclidiana directa, que ignora la forma curva de los datos.