

Tema 6 — Tipos de Problemas de ML, KNN y SVM

PARTE 1 — CLASIFICACIÓN, REGRESIÓN Y AGRUPAMIENTO

1. ¿CÓMO SABER QUÉ TIPO DE PROBLEMA ES?

La clave está en mirar la variable dependiente (lo que querés predecir):

Si la variable dependiente es...		el problema es de...
Númerica	➤	Regresión
Cualitativa (categórica)	➤	Clasificación
No hay (no hay etiqueta)	➤	Agrupamiento

2. APRENDIZAJE SUPERVISADO VS NO SUPERVISADO

Aprendizaje supervisado: técnicas donde se sabe de antemano a qué categoría (o qué valor) pertenece cada dato de entrada. Se tiene un conjunto de entrenamiento ya etiquetado. Incluye Clasificación y Regresión.

Aprendizaje no supervisado: técnicas donde NO se sabe de antemano a qué categoría pertenece cada dato de entrada. Simplemente se explora e intenta agrupar según similitudes entre los datos. Incluye Agrupamiento (Clustering) y también Reducción de Dimensionalidad.

3. REGRESIÓN

Es una técnica de aprendizaje supervisado que predice un **valor continuo** en función de una o más variables independientes.

Ejemplo: predecir el precio de una casa basado en su tamaño y ubicación.

Algoritmos típicos: Regresión Lineal, Regresión Polinómica, Árboles de Regresión, SVR (Support Vector Regression).

Métricas de evaluación: MAE, MSE, RMSE, R^2 (NO se usan Precision/ Recall/F1, que son exclusivas de clasificación).

4. CLASIFICACIÓN

Es una técnica de aprendizaje supervisado, pero en este caso se predicen **categorías** (clases discretas) en vez de un valor continuo.

Ejemplo: predecir si un email es "spam" o "no spam"; predecir si un tumor es "benigno" o "maligno".

Algoritmos típicos: Naive Bayes, Árboles de Decisión, Random Forest, KNN, SVM, Regresión Logística, Redes Neuronales.

Clasificación binaria vs multiclase:

- Binaria: solo 2 clases posibles (Sí/No, Spam/No-spam)
- Multiclase: más de 2 clases posibles (clasificar un animal entre "perro", "gato", "pájaro"). La Regresión Logística, por ejemplo, es usada principalmente para clasificación binaria, pero puede extenderse a multiclase.

Métricas de evaluación: Precision, Recall, Accuracy, F1-Score, Matriz de Confusión.

5. AGRUPAMIENTO (CLUSTERING)

Es una técnica de aprendizaje **no supervisado**: no hay una variable dependiente/etiqueta conocida de antemano. El objetivo es agrupar los datos según similitudes entre ellos, sin saber previamente a qué grupo pertenece cada uno.

Ejemplo: agrupar clientes de un e-commerce según su comportamiento de compra, sin saber de antemano cuántos "tipos" de cliente existen.

Algoritmos típicos: K-Means, DBSCAN, Clustering Jerárquico.

Criterios de evaluación: no se puede usar Accuracy/Precision/Recall (no hay etiquetas reales para comparar). Se usan métricas específicas como el Coeficiente de Silueta, que mide qué tan bien separados y compactos quedaron los clusters.

6. TABLA RESUMEN

	Clasificación	Regresión	Agrupamiento
Tipo de aprendizaje	Supervisado	Supervisado	No supervisado
Variable objetivo	Categórica	Numérica continua	No existe
Ejemplo	Spam/No-spam	Precio de una casa	Segmentar clientes
Algoritmos típicos	Naive Bayes, Árboles, KNN, SVM	Regresión Lineal, SVR	K-Means, DBSCAN
Métricas	Precision, Recall, F1, Accuracy	MAE, MSE, RMSE, R ²	Coeficiente de Silueta

PARTE 2 — K-NEAREST NEIGHBORS (KNN)

7. LA IDEA CENTRAL

KNN es un método de **clasificación** (aunque también puede adaptarse para regresión). La idea es simple: para clasificar una observación nueva, se mira a sus **K vecinos más cercanos**

(los K puntos ya clasificados que están más próximos en el espacio), y la nueva observación se clasifica según la clase que predomina entre esos vecinos (votación por mayoría).

8. EJEMPLO PASO A PASO

Con un dataset ya clasificado (por ejemplo, el dataset Iris con flores de distintas especies representadas por colores):

Con K=1: aparece una observación nueva. Se mira solamente el vecino más cercano. Si ese vecino es verde, la nueva observación se clasifica como verde.

¿Es suficiente con K=1? No necesariamente — puede ser sensible al ruido de un solo punto. Por eso se prueba con K más grande.

Con K=7: se toman los 7 vecinos más cercanos a la nueva observación. Si los 7 son verdes, la clasificación no cambia (sigue siendo verde).

Con K=9, en otra ubicación: de los 9 vecinos más cercanos, 5 son verdes y 4 son amarillos. Como los verdes son mayoría (5 contra 4), la nueva observación se clasifica como **verde**.

9. HIPERPARÁMETROS DE KNN

a) El valor de K

Cuántos vecinos se consideran para la votación. Es el hiperparámetro más importante.

- K muy chico (por ejemplo K=1): muy sensible al ruido, puede dar resultados inestables
- K muy grande: puede "suavizar" demasiado, perdiendo detalle de zonas con clases minoritarias
- Por defecto en scikit-learn: **K=5**

b) El tipo de distancia

Cómo se mide "cercanía" entre puntos: Euclídea, Manhattan, entre otras.

c) El peso (weights) de los vecinos

Los vecinos pueden estar ponderados, dando más peso en la votación a los vecinos más cercanos y menos peso a los más lejanos. Esto responde a la pregunta: **¿es lo mismo que, con K=2, uno de los vecinos esté a 1cm de distancia y el otro a 2m?** Sin ponderar, ambos votos valen igual, aunque uno esté mucho más cerca que el otro — por eso a veces conviene ponderar por distancia.

10. DEBILIDADES DE KNN (MUY PREGUNTADO)

a) Es sensible a conjuntos de datos desbalanceados

Ejemplo: con K=9, si hay 3 vecinos rojos y 6 azules, la nueva observación se clasifica como azul — aunque la observación pudiera estar conceptualmente "más cerca" del grupo rojo en términos individuales, la mayoría numérica (por el desbalance de clases en el dataset general) puede dominar la votación.

b) Es sensible a outliers

Ejemplo: con $K=3$, si los 3 vecinos más cercanos son rojos (pero uno de ellos es en realidad un outlier aislado), la observación se clasifica como roja, aunque ese outlier no sea representativo del patrón real de esa zona.

11. RESUMEN DE KNN

- Es un método de clasificación (adaptable también a regresión)
 - Es sensible a conjuntos de datos no balanceados
 - Es sensible a outliers
 - Requiere elegir bien K , el tipo de distancia, y si se pondera por cercanía
 - En scikit-learn, el valor por defecto de K es 5
-

PARTE 3 — SUPPORT VECTOR MACHINES (SVM)

12. EL PUNTO DE PARTIDA: CLASIFICADORES BASADOS EN UN UMBRAL

Antes de llegar a SVM, hay que entender la evolución de la idea, paso a paso, con un ejemplo de una sola dimensión (masa de ratones, para predecir si son obesos o no).

Umbral aleatorio: si ponés el límite (umbral) de clasificación en cualquier punto entre los dos grupos, una observación nueva se clasifica según de qué lado del umbral cae. Pero un umbral puesto "cualquiera" (no en el lugar óptimo) puede dar clasificaciones erróneas — por ejemplo, una observación nueva podría caer del lado "obeso" cuando en realidad está mucho más cerca de los no-obesos.

13. EL MARGEN Y EL MAXIMAL MARGIN CLASSIFIER

Mejora: en vez de un umbral cualquiera, se pone el umbral en el **punto medio** entre las dos observaciones límite de cada grupo (la observación no-obesa más "cercana" al límite y la obesa más "cercana" al límite).

Margen: es la distancia mínima entre cualquier observación y el umbral. Al poner el umbral en el punto medio entre las dos observaciones límite, el margen es igual a ambos lados, y es el más grande posible.

Maximal Margin Classifier: el clasificador resultante de maximizar ese margen (ponerlo lo más ancho posible entre las dos clases).

El gran problema de este clasificador: es MUY sensible a outliers.

Si aparece un outlier de la clase "no-obeso" muy cerca de la zona de los obesos, un Maximal Margin Classifier se vería obligado a mover el umbral mucho para respetar ese outlier — generando muchas clasificaciones erróneas para el resto de las observaciones nuevas, que en realidad estaban más cerca del grupo correcto sin contar ese outlier.

14. SOFT MARGIN Y SUPPORT VECTOR CLASSIFIER

La solución al problema de sensibilidad a outliers: permitir clasificaciones erróneas a propósito, a cambio de un margen más robusto y estable frente a datos futuros.

Soft Margin (margen blando): cuando se permite la clasificación errónea, la distancia entre las observaciones y el umbral se llama margen blando.

El trade-off bias-varianza aplicado acá:

- Umbral muy sensible al conjunto de entrenamiento (ajustado a cada outlier) → **bajo sesgo, pero alta varianza** → mal desempeño con datos nuevos
- Umbral menos sensible al conjunto de entrenamiento (más general) → **mayor sesgo, pero baja varianza** → mejor desempeño con datos nuevos

¿Cómo se elige el mejor margen blando? El algoritmo lo calcula usando **validación cruzada**: parte el conjunto en varios subconjuntos (por ejemplo 70/30, o 10 subconjuntos), usa pares de observaciones similares para calcular la distancia media del umbral, y valida la clasificación con el conjunto restante. Prueba distintos anchos de margen y se queda con el que mejor generaliza.

Support Vector Classifier: el nombre completo del clasificador que usa margen blando (Soft Margin Classifier). Se llama así porque las observaciones que están en los límites y dentro del Soft Margin se llaman **Support Vectors** (vectores soporte) — son vectores porque son puntos en un espacio de dimensión N , y "soportan" (definen) el área del margen blando.

En distintas dimensiones:

- En 1D: el Support Vector Classifier es un punto/umbral
- En 2D: es una línea
- En 3D: es un plano
- En 4D o más: es un hiperplano (difícil de graficar pero matemáticamente válido)

Ventaja del Support Vector Classifier: puede manejar outliers y clasificaciones superpuestas (a diferencia del Maximal Margin Classifier).

15. EL PROBLEMA QUE NI SIQUIERA EL SOFT MARGIN RESUELVE

¿Qué pasa si los datos NO son linealmente separables en absoluto? Por ejemplo, con una distribución de dosis de una droga donde los pacientes "curados" están en el medio, y los "no curados" están a ambos extremos: no importa dónde pongas el umbral (o el margen blando), siempre vas a tener errores groseros de clasificación, porque el problema no es separable con una línea recta en absoluto.

Ni el Maximal Margin Classifier ni el Support Vector Classifier (soft margin) pueden resolver problemas que no son linealmente separables.

16. LA IDEA CENTRAL DE SVM (Support Vector Machines)

Acá es donde entra específicamente SVM (distinto del Support Vector Classifier, que es un caso más simple/lineal). La idea central de SVM:

1. Empezar con observaciones en una dimensión relativamente baja
2. **Llevar los datos a una dimensión MAYOR**
3. Encontrar un Support Vector Classifier que separe los datos en esa dimensión más alta, en 2 grupos

Ejemplo: si los datos en 1D (dosis) no son separables, se puede crear una segunda dimensión (por ejemplo, $y = \text{dosis}^2$). En este nuevo espacio de 2 dimensiones, los datos SÍ pueden quedar separables con una línea recta (un Support Vector Classifier en 2D).

17. FUNCIONES KERNEL

El algoritmo detrás de SVM usa **Funciones Kernel**, que sistemáticamente buscan Support Vector Classifiers en dimensiones más altas, sin tener que elegir manualmente cómo transformar los datos.

Kernel Polinómico

Toma un parámetro **d** (grado del polinomio):

- Con **d=1**: computa la relación entre cada par de observaciones en 1 dimensión (caso base, sin transformación)
- Con **d=2**: obtiene una segunda dimensión elevando al cuadrado las observaciones (por ejemplo, dosis^2), y calcula la relación entre cada par de observaciones en esas 2 dimensiones para encontrar el Support Vector Classifier
- Con **d=3**: agrega una tercera dimensión (dosis^3), y busca un plano que separe los datos en 2 grupos
- Para cualquier **d=n**: repite el proceso agregando una dimensión adicional

En resumen: el Kernel Polinómico incrementa sistemáticamente las dimensiones, según el parámetro d, calculando en cada caso las relaciones entre las observaciones para encontrar el mejor clasificador.

Kernel Radial (RBF — Radial Basis Function Kernel)

Soporta Support Vector Classifiers en **infinitas dimensiones**.

Simplificando su funcionamiento: el Kernel Radial funciona parecido a un modelo de Vecinos Más Cercanos (Nearest Neighbor) ponderado — utiliza las observaciones más cercanas (vecinas) para clasificar la nueva observación, y las observaciones más lejanas tienen poca influencia en esa clasificación.

18. EL "KERNEL TRICK" (el truco del Kernel)

Este es un punto conceptual clave que se pregunta seguido:

Las funciones Kernel NO realizan una verdadera transformación del espacio. Solo calculan la relación entre pares de observaciones como si estuvieran en una dimensión mayor, pero sin hacer efectivamente todo el cálculo matemático de proyectar cada punto a esa dimensión más alta.

¿Por qué es esto una ventaja? Porque este "truco" reduce enormemente el tiempo de cómputo necesario — se evita toda la matemática pesada relacionada con la transformación real del espacio a dimensiones muy altas (o incluso infinitas, como en el caso del Kernel Radial), pero se obtiene el mismo resultado que si esa transformación se hubiera hecho.

19. TABLA RESUMEN DE LA EVOLUCIÓN CONCEPTUAL

Clasificador	Maneja outliers	Maneja no-linealidad	Margen
Maximal Margin Classifier	No (muy sensible)	No	Margen máximo (duro)
Support Vector Classifier	Sí	No	Margen blando (Soft Margin)
Support Vector Machine (SVM)	Sí	Sí (con Kernels)	Margen blando en dimensión alta

Hiperparámetro clave de SVM: el parámetro C controla cuánto se permite el margen blando (cuántas clasificaciones erróneas tolerar). Un C muy grande penaliza mucho los errores (se acerca a un margen duro, riesgo de overfitting); un C muy chico permite más errores (margen más ancho, más generalización pero riesgo de underfitting).

PREGUNTAS DE PRÁCTICA (formato final real)

Pregunta 1 (Desarrollo)

Explique cómo se determina si un problema es de Clasificación, Regresión o Agrupamiento. Dé un ejemplo de cada uno.

Pregunta 2 (V/F)

- a) KNN es un método de aprendizaje no supervisado.
- b) KNN es sensible tanto a datos desbalanceados como a outliers.
- c) El valor por defecto de K en scikit-learn es 1.
- d) Ponderar los vecinos por distancia permite que los vecinos más cercanos tengan más peso en la votación que los más lejanos.

Pregunta 3 (Desarrollo)

Explique qué es el Maximal Margin Classifier y por qué es problemático usarlo cuando hay outliers en los datos.

Pregunta 4 (Desarrollo)

¿Qué es el "Kernel Trick" en Support Vector Machines? ¿Por qué es ventajoso computacionalmente?

Pregunta 5 (V/F)

- a) Un Support Vector Classifier (con margen blando) puede resolver cualquier problema, incluso si los datos no son linealmente separables.
 - b) Las observaciones que definen el margen blando se llaman Support Vectors.
 - c) El Kernel Radial (RBF) solo puede trabajar en un número finito y pequeño de dimensiones.
 - d) SVM primero lleva los datos a una dimensión mayor, y luego busca un Support Vector Classifier que los separe en esa nueva dimensión.
-

RESPUESTAS MODELO

Respuesta 1

Se determina mirando la variable dependiente (lo que se quiere predecir): si es numérica continua, el problema es de Regresión (ejemplo: predecir el precio de una casa según su tamaño). Si es categórica/cualitativa, el problema es de Clasificación (ejemplo: predecir si un email es spam o no). Si no hay ninguna variable dependiente o etiqueta conocida de antemano, el problema es de Agrupamiento (ejemplo: segmentar clientes de un e-commerce según patrones de compra, sin categorías predefinidas).

Respuesta 2

a) **FALSO.** KNN es un método de aprendizaje SUPERVISADO — necesita un conjunto de datos ya clasificado (etiquetado) para poder comparar la nueva observación contra sus vecinos conocidos.

b) **VERDADERO.** KNN es sensible a datos desbalanceados (la clase mayoritaria puede dominar la votación aunque la observación esté conceptualmente más cerca de la clase minoritaria) y también es sensible a outliers (un vecino cercano que sea un caso atípico puede distorsionar la clasificación).

c) **FALSO.** El valor por defecto de K en scikit-learn es 5, no 1.

d) **VERDADERO.** Ponderar por distancia hace que los vecinos más cercanos influyan más en la votación final que los vecinos más lejanos, en vez de que todos los votos valgan lo

mismo sin importar la distancia.

Respuesta 3

El Maximal Margin Classifier es el clasificador que ubica el umbral de separación entre dos clases de forma que el margen (la distancia mínima entre cualquier observación y el umbral) sea el más grande posible, colocándolo en el punto medio entre las observaciones límite de cada clase.

Es problemático con outliers porque, si aparece una observación atípica de una clase muy cerca de la zona de la otra clase, el clasificador se ve obligado a mover el umbral significativamente para mantener el margen máximo respecto a ese outlier. Esto puede generar muchas clasificaciones erróneas para observaciones futuras que, sin contar el outlier, en realidad estaban más cerca del grupo correcto. Por eso se dice que este clasificador tiene bajo sesgo pero alta varianza: se ajusta demasiado al conjunto de entrenamiento específico y generaliza mal.

Respuesta 4

El Kernel Trick consiste en que las funciones Kernel de SVM no realizan una transformación real del espacio de los datos a una dimensión mayor. En cambio, calculan directamente la relación (producto interno) entre cada par de observaciones, como si esas observaciones estuvieran en una dimensión más alta, sin necesidad de proyectar efectivamente cada punto a esa dimensión.

Es ventajoso computacionalmente porque evita toda la matemática pesada asociada a la transformación real del espacio — especialmente relevante en casos como el Kernel Radial, que soporta dimensiones infinitas, donde una transformación explícita sería imposible de calcular directamente. El Kernel Trick permite obtener el mismo resultado que si se hubiera hecho la transformación, pero con un costo computacional mucho menor.

Respuesta 5

a) **FALSO.** El Support Vector Classifier (con margen blando) sigue siendo un clasificador LINEAL — no puede resolver problemas donde los datos no son linealmente separables (por ejemplo, cuando una clase está "rodeada" por la otra). Para esos casos se necesita SVM con Kernels, que lleva los datos a una dimensión mayor donde sí pueden ser separables linealmente.

b) **VERDADERO.** Los Support Vectors son las observaciones ubicadas en los límites y dentro del margen blando; son las que "sostienen" o definen el área del Soft Margin.

c) **FALSO.** Es al revés: el Kernel Radial (RBF) soporta Support Vector Classifiers en infinitas dimensiones, precisamente gracias al Kernel Trick, que evita tener que calcular explícitamente esa transformación.

d) **VERDADERO.** Esa es la idea central de SVM: primero se lleva el problema a una dimensión mayor (usando funciones Kernel), y luego se busca un Support Vector Classifier que separe los datos en esa nueva dimensión donde sí son linealmente separables.