

Trabajo Práctico 1 - Grupo 05

Integrante	Padrón
Malena Sein	112295
Candela Piccin	109760
Javier Zardain	102521
Bruno Pezman	110457
Alexis Maximiliano Torres Vargas	111449

Ejercicio 1: Análisis Exploratorio de Datos

1. Descripción del dataset:

1.1. Cantidad de registros y columnas.

El conjunto de datos comprende los registros de viajes realizados por los taxis amarillos (Yellow Cab) en la ciudad de Nueva York durante los meses abril, mayo y junio del año 2025. Los datos fueron obtenidos de la NYC Taxi and Limousine Commission (TLC).

Dimensión	Valor
Registros Totales	12.885.358
Columnas originales	20

1.2. Clasificación de variables.

Las 20 columnas originales se clasificaron en cualitativas (categóricas) y cuantitativas (numéricas):

Variable	Tipo	Descripción / Relevancia
VendorID	Cualitativa	Código del proveedor de la compañía.
RatecodeID	Cualitativa	Código de la tarifa aplicada al viaje.
store_and_fwd_flag	Cualitativa	Indicador si el vehículo fue almacenado antes de enviarse.
PULocationID	Cualitativa	ID de la zona de recogida.
DOLocationID	Cualitativa	ID de la zona de destino.
payment_type	Cualitativa	Tipo de pago realizado por el pasajero
tpep_pickup_datetime	Cuantitativa	Fecha y hora de inicio del viaje.
tpep_dropoff_datetime	Cuantitativa	Fecha y hora de fin del viaje.
passenger_count	Cuantitativa	Número de pasajeros.
trip_distance	Cuantitativa	Distancia recorrida en millas.


fare_amount	Cuantitativa	Tarifa base del viaje.
tip_amount	Cuantitativa	Cantidad de propina.
mta_tax	Cuantitativa	Impuesto.
tolls_amount	Cuantitativa	Cantidad de peajes.
improvement_surcharge	Cuantitativa	Recargo por mejora del servicio.
total_amount	Cuantitativa	Monto total cobrado.
congestion_surcharge	Cuantitativa	Recargo por congestión.
Airport_fee	Cuantitativa	Tarifa de aeropuerto.
cbd_congestion_fee	Cuantitativa	Tarifa por congestión.

2. Preprocesamiento:

2.1. Datos faltantes

Al analizar la presencia de valores nulos, se identificó que cinco columnas presentan exactamente el mismo porcentaje de datos faltantes (~24.48%): passenger_count, RatecodeID, store_and_fwd_flag, congestion_surcharge y Airport_fee.

La investigación reveló que estos nulos no son aleatorios (MCAR) sino que están perfectamente correlacionados: todos los registros afectados corresponden a viajes bajo el esquema Flex Fare (payment_type = 0), un modelo tarifario dinámico basado en plataformas e-hail que no sigue la estructura de taxímetro tradicional. En estos viajes, las variables de recargo y algunos metadatos no se registran como componentes separados, ya que el monto final es fijado por la plataforma de antemano.



Decisión de tratamiento: los nulos no fueron imputados ni eliminados, dado que representan una ausencia de información estructuralmente válida. Para diferenciar ambos tipos de viaje de forma explícita, se creó la variable binaria `flex_fare_trip_flag` (0 = Flex Fare, 1 = taxímetro).

2.2. Columnas eliminadas.

No se eliminaron columnas del dataset. Todas las variables originales conservan información útil para al menos alguna de las preguntas de investigación planteadas.

2.3. Correlaciones destacables.

El análisis de correlaciones entre las variables cuantitativas reveló las siguientes relaciones destacables:

`fare_amount` ↔ `total_amount` ($r \approx 0.98$): La tarifa base domina el monto total. Es la correlación más fuerte del dataset y confirma que el monto final sigue directamente a la tarifa registrada por el taxímetro.

`trip_distance` ↔ `total_amount` ($r \approx 0.91$): La distancia recorrida es el principal predictor del costo total. Relación positiva y fuerte, confirmada por la Hipótesis 2.

`trip_distance` ↔ `fare_amount` ($r \approx 0.93$): La tarifa base crece linealmente con la distancia, consistente con la estructura de tarifa por milla del TLC (\$3.50 de arranque + \$0.70 cada 1/5 de milla).

`tip_amount` ↔ `fare_amount` ($r \approx 0.54$): Correlación moderada. A mayor tarifa, mayor propina, aunque con alta dispersión por los diferentes hábitos de los pasajeros y el tipo de viaje.

`congestion_surcharge` ↔ `cbd_congestion_fee` ($r \approx 0.45$): Ambos recargos suelen aplicarse juntos en viajes por el centro de Manhattan, ya que representan instrumentos regulatorios distintos (MTA vs. CBD) para los mismos corredores geográficos.

2.4. Nuevos *features* generados.

Se crearon las siguientes variables derivadas para enriquecer el análisis y facilitar la respuesta a las preguntas de investigación:

Variable	Descripción
<code>trip_duration_min</code>	Duración del viaje en minutos (dropoff – pickup). Permite análisis temporales sin depender del taxímetro.
<code>pickup_hour</code>	Hora del día (0–23) en que inicia el viaje. Base para análisis de horarios pico.
<code>pickup_dayofweek</code>	Día de la semana (0=Lunes, 6=Domingo). Permite diferenciar hábitos entre días hábiles y fines de semana.
<code>franja_horaria</code>	Categoría horaria: Madrugada (22–6), Mañana (6–12), Tarde (12–18), Noche (18–22).
<code>fare_per_mile</code>	Tarifa base por milla (solo taxímetro). Indicador de eficiencia y congestión. Nulo para Flex Fare.

tip_pct	Porcentaje de propina sobre la tarifa base (solo tarjeta). Permite comparar propinas independientemente del monto.
flex_fare_trip_flag	Variable binaria: 0 = viaje Flex Fare, 1 = viaje con taxímetro. Creada para separar los dos tipos de viaje.
pickup_month	Mes del viaje (4=Abril, 5=Mayo, 6=Junio). Permite análisis de estacionalidad mensual.

2.5. Valores atípicos: técnicas usadas, qué se detectó y qué decisión se tomó.

El criterio de filtrado de outliers se basó en reglas de negocio del TLC y no en métodos estadísticos puros (como IQR o z-score), dado que el dominio del problema impone límites físicos y regulatorios claros. Se diferencié entre viajes con taxímetro y Flex Fare para evitar eliminar observaciones válidas por diferencias estructurales.

Duración del viaje: se conservaron únicamente viajes con duración entre 1 y 300 minutos. Se detectaron registros con timestamps invertidos o nulos que generaban duraciones negativas o extremadamente altas.

Distancia: entre 0.1 y 200 millas. Se descartaron viajes con distancia cero (ausencia de desplazamiento real) y valores extremos que exceden el alcance geográfico del servicio (se detectaron valores de hasta 170,000 millas asumimos que por errores de GPS).

Tarifa base: mínimo \$3 USD (inferior al cargo inicial del TLC). Monto total: máximo \$300 USD. Los valores negativos se conservaron cuando su magnitud absoluta era coherente con un reembolso o ajuste legítimo.


Tasas e impuestos: se filtraron valores fuera de los rangos posibles del TLC: $mta_tax \in \{0, 0.5\}$, $improvement_surcharge \in \{0, 1.0\}$, $congestion_surcharge \in \{0, 0.75, 2.5\}$, $cbd_congestion_fee \in \{0, 0.75\}$.

Pasajeros (solo taxímetro): entre 1 y 6, acorde a la capacidad máxima legal. En viajes Flex Fare esta variable no se filtró al estar siempre nula por diseño.

Fechas: se conservaron únicamente viajes con fecha de dropoff en abril, mayo o junio de 2025, eliminando registros de años distintos o meses fuera del período de análisis.

3. Planteo y análisis de hipótesis.


Hipótesis 1 — Horarios pico: La mayor concentración de viajes ocurre en los horarios de entrada y salida laboral (7–10 hs y 17–20 hs).



Para verificar o rechazar la hipótesis graficamos la distribución de viajes a lo largo del día en días hábiles.

Observamos que los saltos y picos de cantidad de viajes se dieron alrededor de las 7-9 am y 5-7 pm, sugiriendo que la mayor concentración de viajes se da en los horarios de entrada y salida laboral, es decir, en los horarios pico. Verificamos la hipótesis.

Hipótesis 2 — Precio y distancia: Existe una correlación positiva y fuerte entre la distancia recorrida y el costo total del viaje.



Graficando la relación entre la distancia recorrida y el monto total podemos observar una correlación positiva fuerte entre las dos variables, con un coeficiente de Pearson de **0.9328**. A medida que la distancia aumenta, el precio generalmente aumenta.


La correlación no es perfectamente lineal porque otros componentes tarifarios adicionales también influyen en el monto total.

Verificamos la hipótesis, concluyendo que la distancia es un factor determinante en el costo del viaje, aunque no es el único.

Hipótesis 3 — Concentración geográfica: La mayoría de los viajes inician y terminan en Manhattan, especialmente en zonas céntricas y aeropuertos.


Para validar esta hipótesis, se realizó un proceso de enriquecimiento de datos asociando los identificadores numéricos de las zonas de recogida y destino con sus respectivos nombres de zona (borough), transformando así datos crudos en información geográfica significativa.

El análisis reveló que Manhattan es el punto central de la actividad de taxis, concentrando el 85% de todos los viajes de origen. Se valida la suposición inicial de la hipótesis. El segundo borough más relevante es Queens, abarcando el 10% de viajes de origen. Cifra impulsada por una significativa demanda generada por los aeropuertos JFK y LaGuardia. Brooklyn representa el 4% de los viajes, mientras que el Bronx y Staten Island muestran una participación marginal. Esta distribución es consistente con el patrón operativo tradicional del servicio de taxis amarillos de Nueva York, que históricamente ha centrado sus operaciones en Manhattan y sus alrededores más cercanos. Verificamos la hipótesis.




4. Visualizaciones y preguntas de investigación:

4.1. ¿En qué horarios del día se concentra la mayor cantidad de viajes?




Se analizó la distribución de viajes por hora del día, diferenciando días hábiles (lunes a viernes) de fines de semana. Se utilizó un histograma de barras donde las horas pico (7–9 hs y 17–19 hs) se resaltan en color salmón para facilitar la identificación visual. En días hábiles se confirman dos picos claros: uno matutino entre las 8 y las 9 hs, y uno vespertino entre las 17 y las 19 hs, ambos asociados a los horarios de entrada y salida laboral. El hueco más profundo ocurre entre las 3 y las 5 hs. En fin de semana el patrón cambia: la actividad nocturna se extiende hasta las 23 hs, y el pico matinal desaparece. El viernes vespertino concentra el máximo de toda la semana.

4.2. ¿Cómo se relaciona la distancia del viaje con el costo total?




Se utilizó un scatter plot con muestra de 30,000 viajes y una regresión lineal superpuesta, limitando los ejes a rangos representativos (0–25 millas, \$3–\$100). Se excluyeron los viajes Flex Fare, ya que no siguen la estructura tarifaria por distancia. La regresión lineal arroja un coeficiente de Pearson de ≈ 0.93 y una pendiente de \$4.53 USD por milla adicional. La relación es positiva y fuerte, validando la Hipótesis 2. La dispersión se incrementa en viajes largos, atribuible a peajes, recargos de aeropuerto y otros factores independientes de la distancia.

4.3. ¿Cómo varía el porcentaje de propina según el monto del viaje?




Se calculó el porcentaje de propina como $\text{tip_amount} / \text{total_amount} \times 100$, excluyendo pagos en efectivo (donde la propina no se registra). Se graficó la propina promedio por bins de \$10 para identificar tendencias. El porcentaje de propina es más variable en viajes de bajo monto, donde pequeñas diferencias absolutas generan grandes variaciones porcentuales. A partir de los \$30, el comportamiento se estabiliza y muestra una tendencia creciente hasta los \$100. Por encima de ese monto, la propina relativa tiende a disminuir levemente, posiblemente porque los pasajeros de viajes caros (aeropuertos, tarifas especiales) tienen distintos hábitos de propina.

4.4. ¿Qué zonas concentran la mayor cantidad de viajes?



Se graficaron los top 15 boroughs y zonas de origen (pickup) y destino (dropoff) mediante gráficos de barras horizontales. Previamente se realizó un join con el archivo taxi_zone_lookup.csv del TLC para traducir los IDs numéricos a nombres de zonas y boroughs. Manhattan concentra el 85% de los orígenes. Las zonas más frecuentes de origen son Midtown Center, Upper East Side North y Penn Station/Madison Sq West. En destinos el patrón es similar aunque con mayor presencia de zonas residenciales del Upper West Side. JFK y LaGuardia Airport aparecen consistentemente en el top 15 tanto de orígenes como de destinos.


4.5. ¿Cómo cambia el precio por milla según el horario del día? viaja mas o menos gente en esos horarios?



Se combinó en un gráfico de doble eje el precio por milla mediano (línea naranja) y el volumen de viajes (barras celestes) agrupados por hora del día. Solo se consideraron viajes con taxímetro y fare_per_mile entre \$1 y \$30. El precio por milla es más alto de madrugada (0–5 hs), cuando el volumen es mínimo pero los trayectos son más largos. Durante el pico matinal (8–9 hs) el precio por milla cae a pesar del alto volumen, porque los viajes son cortos y directos. La noche (18–22 hs) muestra un leve repunte del precio/milla coincidente con el aumento de la congestión en Manhattan.

4.6. ¿Cuánto del costo del viaje corresponde a impuestos, propina, fees y recargos?

Se calculó la proporción de cada componente del monto total sobre el universo de viajes con taxímetro (excluyendo Flex Fare, donde no hay desglose). Se agruparon los componentes en: tarifa base, propina, impuestos y recargos regulados (MTA tax, improvement surcharge, congestion surcharge, CBD congestion fee, Airport fee), y otros costos variables (peajes y extras). Se visualizó con un gráfico de torta. La tarifa base representa aproximadamente el 64.79% del costo total. Las propinas (solo tarjeta) contribuyen el 12.76%, los impuestos y recargos regulados el 14.96%, y peajes y extras el 7.49%.



4.7. ¿El origen/destino influyen en la cantidad de propina recibida?

Se calculó la propina media por zona de origen y destino, considerando únicamente pagos con tarjeta. Se graficaron las top 15 zonas con mayor propina media en ambas dimensiones. Las zonas de aeropuerto (JFK, LaGuardia, Newark) y las zonas de alto poder adquisitivo (Upper East Side, Midtown) muestran propinas medias significativamente más altas. Esto sugiere que tanto el perfil socioeconómico del pasajero como el tipo de viaje (aeropuerto vs. urbano) influyen en el comportamiento de propinas. Las zonas de destino con mayor propina coinciden en gran medida con las de origen, indicando que los viajes premium son bidireccionales.


4.8. ¿Cómo se distribuyen las duraciones de los viajes y cómo varían por día de la semana o franja horaria?

La duración media de los viajes es de aproximadamente 14 minutos. Se observa una distribución asimétrica a la derecha, con la mayoría de los viajes concentrados entre 5 y 30 minutos. Los viajes de fin de semana en la franja nocturna (18–22 hs) presentan la mayor duración promedio, mientras que los días hábiles en horas pico muestran duraciones medias similares al promedio general, a pesar de la mayor congestión, porque los trayectos tienden a ser más cortos y directos.

4.9. ¿Hay zonas con poca cobertura de red en la ciudad?

Se identificaron zonas con potenciales problemas de cobertura de red a partir de la distribución geográfica y el contexto urbano. Las áreas insulares como Governor's Island y Roosevelt Island presentan baja conectividad debido a su aislamiento y menor infraestructura. Asimismo, los aeropuertos como John F. Kennedy International Airport y LaGuardia Airport muestran dificultades de señal, probablemente asociadas a su ubicación periférica y a restricciones operativas. Por otro lado, en Manhattan —que concentra la mayor cantidad de viajes— también se registran problemas de cobertura, atribuibles a la alta densidad poblacional, la saturación de la red en horas pico y la interferencia de edificaciones de gran altura. En conjunto, esto indica que la calidad de la conectividad varía según la zona y puede verse afectada tanto por factores geográficos como por la demanda de uso.

Tasa de store-and-forward por zona de pickup — abril, mayo, junio 2025



5. Conclusión General

Este análisis exploratorio de los datos de viajes de Yellow Cab de NYC para abril, mayo y junio de 2025 reveló patrones significativos y características clave del servicio.

Calidad y Preparación de Datos:

Se identificó una gran cantidad de datos (12.8M registros), con variables de diversos tipos.

La gestión de valores nulos fue crucial, especialmente para las columnas `passenger_count`, `RatecodeID`, `store_and_fwd_flag`, `congestion_surcharge` y `Airport_fee`, que mostraron una correlación perfecta de ausencia de datos. Esto se atribuyó a viajes tipo 'Flex Fare', que manejan una estructura tarifaria diferente. Se creó una bandera `flex_fare_trip_flag` para diferenciar estos viajes.

El filtrado de outliers se aplicó para eliminar registros anómalos relacionados con la duración del viaje, la distancia, los montos y el número de pasajeros, asegurando la consistencia de los datos.

Patrones de Viaje y Horarios:

Se confirmó la hipótesis de que la mayor concentración de viajes ocurre en las horas pico laborales (7-9 AM y 5-7 PM) durante los días hábiles. Los fines de semana muestran un patrón diferente, con mayor actividad nocturna.

Además, la duración promedio de los viajes varía según el día de la semana y la franja horaria, siendo la franja Tarde (12–18 hs) y Noche (18–22 hs) las que concentran los viajes de mayor duración, con los viernes y sábados mostrando las medianas más altas por día de la semana, mientras que los picos de la mañana y la tarde en días hábiles se caracterizan por viajes más cortos y directos.

Relación entre Costo y Distancia:

Existe una correlación positiva y fuerte (coeficiente de Pearson ≈ 0.93) entre la distancia recorrida (`trip_distance`) y el costo total del viaje (`total_amount`). Por cada milla adicional, el monto total aumenta en promedio \$4.53 USD. Esto remarca la relevancia de la distancia como principal motor del costo, aunque no el único.

Aspectos Geográficos:

La vasta mayoría de los viajes (85%) se originan y/o terminan en Manhattan, con Queens (principalmente aeropuertos JFK y LaGuardia) como el segundo borough más relevante. Esto valida la hipótesis de una fuerte concentración geográfica en las zonas céntricas y aeroportuarias.

Midtown Center, Upper East Side y Penn Station/Madison Sq West son consistentemente las zonas de mayor actividad (pickup y dropoff).

El análisis de la `store_and_fwd_flag` reveló zonas con problemas de conectividad (ej. Governor's Island, Roosevelt Island y áreas densas de Manhattan), indicando posibles limitaciones de infraestructura de red en ciertas ubicaciones.

Componentes del Costo y Propinas:

La tarifa base (`fare_amount`) constituye la mayor parte del costo total (aproximadamente 64.79%), seguida por impuestos y recargos (14.96%), propinas (12.76%) y otros costos (7.49%). El porcentaje de propina (para pagos no en efectivo) muestra una mayor variabilidad en viajes de bajo monto, estabilizándose y mostrando una ligera tendencia al aumento hasta los 100 USD, para luego disminuir levemente en viajes de mayor valor.

Componentes del Costo y Propinas:

La tarifa base (`fare_amount`) constituye la mayor parte del costo total (aproximadamente 64.79%), seguida por impuestos y recargos (14.96%), propinas (12.76%) y otros costos (7.49%). El análisis por hora del día muestra que la madrugada (0–5 hs) presenta el precio por milla más alto a pesar del bajo volumen, dado que los viajes son más fluidos por la ausencia de tráfico pero tienden hacia destinos más alejados o con recargos.

El porcentaje de propina (para pagos no en efectivo) muestra una mayor variabilidad en viajes de bajo monto, estabilizándose y mostrando una ligera tendencia al aumento hasta los 100 USD, para luego disminuir levemente en viajes de mayor valor.

Zonas con poca cobertura de red:

De acuerdo al análisis de los datos y a la proyección sobre el mapa de New York podemos concluir que las zonas con problemas de conectividad están claramente delimitadas y no son aleatorias. Es especialmente llamativo el caso de Manhattan, una de las zonas más caras del mundo, presente tantos problemas de conectividad, evidenciando faltas de inversión o planeamiento. Enfocándonos puntualmente en el dataset tratado, ya que la gran mayoría de los viajes son también en esa zona, sería conveniente que los taxis busquen otra estrategia para enviar los datos.

EJ2: Modelos de Clasificación Binaria

1. Introducción

El objetivo de este trabajo es construir, entrenar y evaluar distintos modelos de clasificación binaria capaces de predecir si lloverá o no al día siguiente en determinadas ciudades de Australia, utilizando información meteorológica registrada durante el día actual.

La variable objetivo del problema es **RainTomorrow**, la cual indica si al día siguiente se registraron precipitaciones. Esta variable toma dos valores posibles: **Yes**, en caso de que llueva, y **No**, en caso contrario. Por lo tanto, el problema planteado corresponde a una tarea de clasificación binaria.

A nuestro grupo se le asignaron registros correspondientes a los siguientes estados australianos:

- Queensland
- Victoria
- Australia Meridional
- Australia Occidental

A partir de estos datos, se entrenaron y compararon distintos modelos de Machine Learning: Árbol de Decisión, Random Forest y XGBoost. La comparación se realizó utilizando métricas como Accuracy, Precision, Recall, F1 Score y ROC AUC, prestando especial atención al Recall, ya que en este problema se consideró más grave predecir que no lloverá cuando en realidad sí lloverá.

2. Entendimiento de los datos

2.1 Vistazo inicial al contenido

En una primera instancia, se inspeccionaron las primeras filas del dataset para observar su estructura general. Esto permitió identificar las columnas disponibles, el formato de los datos y

la presencia de variables numéricas y categóricas.

Entre las variables disponibles se encuentran datos de temperatura, lluvia, evaporación, horas de sol, dirección y velocidad del viento, humedad, presión atmosférica, nubosidad, ubicación, fecha y las variables **RainToday** y **RainTomorrow**.

2.2 Filtrado por estados asignados

El dataset original contenía registros de distintas ciudades de Australia. Como el trabajo se enfocaba únicamente en los estados asignados al grupo, se filtraron las observaciones correspondientes a las ciudades pertenecientes a:

- Queensland
- Victoria
- Australia Meridional
- Australia Occidental

Luego del filtrado, la cantidad de registros se redujo de 145.460 filas a 74.736 filas.

Este paso fue importante para trabajar solamente con los datos correspondientes al alcance definido para el grupo.

2.3 Descripción del dataset

El dataset utilizado contiene registros meteorológicos diarios obtenidos por estaciones ubicadas en distintas ciudades de Australia. Cada fila representa una observación diaria para una ubicación determinada, mientras que cada columna representa una variable climática registrada durante ese día.

Originalmente, el dataset contiene variables numéricas y categóricas relacionadas con temperatura, precipitaciones, humedad, presión atmosférica, nubosidad, viento y localización.

Entre las variables más relevantes se encuentran:

- **Date:** Fecha de la observación.
- **Location:** Ciudad o estación meteorológica donde se tomó el registro.
- **MinTemp:** Temperatura mínima del día(°C) .
- **MaxTemp:** Temperatura máxima del día(°C) .
- **Rainfall:** Cantidad de lluvia registrada durante el día(mm) .
- **Evaporation:** Evaporación registrada en las 24 horas previas a las 9 a. m.(mm).
- **Sunshine:** Cantidad de horas de sol durante el día.
- **WindGustDir:** Dirección de la ráfaga de viento más fuerte.
- **WindGustSpeed:** Velocidad de la ráfaga de viento más fuerte(km/h) .
- **Humidity9am:** Humedad a las 9 a. m. (%) .
- **Humidity3pm:** Humedad a las 3 p. m. (%) .
- **Pressure9am:** Presión atmosférica a las 9 a. m. (hPa) .
- **Pressure3pm:** Presión atmosférica a las 3 p. m. (hPa) .

- **Cloud9am:** Nubosidad a las 9 a. m. (oktas) .
- **Cloud3pm:** Nubosidad a las 3 p. m. (oktas) .
- **RainToday:** Indica si llovió durante el día actual.
- **RainTomorrow:** Variable objetivo: indica si lloverá al día siguiente.

3. Análisis

3.1 Análisis inicial de variables


Antes de entrenar los modelos, se realizó un análisis inicial del dataset para conocer el tipo de variables, la presencia de valores nulos y posibles inconsistencias.

Se identificaron variables numéricas, como temperaturas, humedad, presión, nubosidad y velocidad del viento; y variables categóricas, como ubicación, dirección del viento, **RainToday** y **RainTomorrow**.

Durante esta etapa se observó que algunas columnas presentaban valores faltantes, especialmente variables como **Evaporation**, **Sunshine**, **Cloud9am**, **Cloud3pm** y algunas variables relacionadas con dirección del viento.

También se detectó una inconsistencia en **Cloud3pm**, ya que la nubosidad medida en oktas debería tomar valores entre 0 y 8, pero apareció al menos un valor igual a 9. Este tipo de revisión es importante porque permite detectar errores que podrían afectar el entrenamiento de los modelos.

Además se detectaron outliers en distintas variables, todos dentro de rangos aceptables o pertenecientes a eventos críticos pocos frecuentes, tales como ciclones, por lo tanto no los tomaremos como errores de medición.



Se observa que algunas variables presentan una proporción considerable de valores faltantes. Por este motivo, fue necesario aplicar una estrategia de imputación antes de entrenar los modelos. El análisis de nulos también permite identificar columnas que podrían aportar menos información o requerir un tratamiento especial.

3.2 Análisis exploratorio de la variable objetivo


La variable objetivo del problema es **RainTomorrow**. Esta variable indica si al día siguiente llovió o no.

Al analizar su distribución, se observó que la clase **No** es mayoritaria. Esto significa que en el dataset hay más días en los que no llueve al día siguiente que días en los que sí llueve.

Este desbalance es importante porque puede afectar el aprendizaje de los modelos. Un modelo podría obtener una accuracy relativamente alta prediciendo muchas veces la clase mayoritaria, pero fallar al detectar correctamente los días de lluvia.

Por este motivo, no se utilizó únicamente la accuracy para evaluar los modelos, sino también métricas como Precision, F1, ROC AUC y especial énfasis en Recall,.

También se analizó la relación entre **RainToday** y **RainTomorrow**.



Se observa que cuando llueve durante el día actual, aumenta la proporción de casos en los que también llueve al día siguiente. Por lo tanto, **RainToday** puede aportar información útil para predecir la variable objetivo, aunque no determina por sí sola el resultado.

3.3 Variables climáticas relevantes



Luego se analizaron algunas variables meteorológicas en relación con **RainTomorrow**, con el objetivo de identificar posibles patrones útiles para la clasificación.



Algunas variables mostraron diferencias relevantes entre los días donde llueve al día siguiente y los días donde no llueve. En particular:

Humidity3pm: valores más altos suelen estar asociados con mayor probabilidad de lluvia.

Cloud3pm: mayor nubosidad puede relacionarse con lluvia al día siguiente.

Pressure3pm: valores más bajos pueden estar asociados a condiciones climáticas inestables.





Los boxplots muestran que algunas variables presentan distribuciones distintas según el valor de **RainTomorrow**. En particular, los registros donde llueve al día siguiente tienden a presentar mayor humedad y mayor nubosidad. Esto resulta coherente desde el punto de vista meteorológico y justifica que estas variables sean consideradas relevantes para el entrenamiento de los modelos.

4. Limpieza y transformación de datos

Luego del análisis exploratorio, se prepararon los datos para poder entrenar los modelos.

Se tomó la decisión de eliminar la variable **evaporation**, ya que falta una gran cantidad de datos, y además se identificó que no era una variable que ayude a determinar si llueve o no al día siguiente, en comparación con la humedad, las horas de sol y la porción del cielo cubierto por nubes.

En primer lugar, se trataron los valores faltantes. Para las variables numéricas se utilizó la mediana agrupada por **Location**, mientras que para las variables categóricas se utilizó la moda agrupada por **Location**.

Esta estrategia se eligió porque las condiciones climáticas pueden variar entre ciudades. Por lo tanto, imputar según la ubicación permite conservar mejor las características propias de cada región.

En los casos donde no era posible calcular la mediana o la moda por ubicación, se utilizó el valor global de la variable.

Además, se corrigieron o trataron valores inconsistentes, como el caso de **Cloud3pm = 9**, ya que la nubosidad medida en oktas debería encontrarse entre 0 y 8.

La variable **Date** fue convertida a formato fecha y utilizada para crear una nueva variable: **Estacion**. Luego, **Date** fue eliminada del conjunto de predictores, ya que en su formato original no podía ser utilizada directamente por los modelos.

También se transformaron las variables categóricas:

- **RainToday** y **RainTomorrow** se codificaron como variables binarias numéricas.
- Las variables categóricas con más de dos valores, como **Location**, **Estacion**, y las direcciones del viento, se transformaron mediante One Hot Encoding.

5. División train/test y balanceo de clases

Una vez preparado el dataset, se separaron las variables predictoras de la variable objetivo.

La variable objetivo fue **RainTomorrow**, mientras que el resto de las columnas fueron utilizadas como variables independientes.

Luego, el dataset se dividió en conjunto de entrenamiento y conjunto de prueba, utilizando una proporción de 80% para entrenamiento y 20% para prueba.

Debido al desbalance observado en la variable objetivo, se aplicó una técnica de balanceo sobre el conjunto de entrenamiento. El balanceo de clases se realizó mediante oversampling de la clase minoritaria, duplicando registros de la clase menos frecuente hasta igualar la cantidad de ejemplos de la clase mayoritaria.

Es importante destacar que el balanceo se aplicó únicamente sobre el conjunto de entrenamiento. El conjunto de prueba no fue balanceado, ya que debe representar datos no vistos **y conservar una distribución realista del problema.**

6. Modelos entrenados

6.1 Criterio general de entrenamiento y selección de modelos

Para todos los modelos entrenados se utilizó **GridSearchCV** con validación cruzada de 5 particiones (**cv = 5**). Esta técnica permite evaluar distintas combinaciones de hiperparámetros y seleccionar aquella que obtiene el mejor rendimiento promedio durante la validación cruzada.

La métrica utilizada para seleccionar el mejor modelo fue **F1 Score**. Se eligió esta métrica porque combina Precision y Recall en una única medida, permitiendo buscar un equilibrio entre ambos aspectos.

En este problema, si bien se le da especial importancia al **Recall**, ya que se busca reducir la cantidad de falsos negativos, también es necesario considerar la **Precision**, para evitar que el modelo prediga demasiados casos como lluvia cuando en realidad no llueve.

Por este motivo, el F1 Score resulta una métrica adecuada para la selección de hiperparámetros, ya que permite optimizar el modelo considerando simultáneamente la capacidad de detectar días lluviosos y la calidad de esas predicciones.

Una vez seleccionado el mejor modelo mediante validación cruzada, se evaluó su rendimiento final sobre el conjunto de prueba utilizando las métricas Accuracy, Precision, Recall, F1 Score, ROC AUC y matriz de confusión.

Es de aclarar, que se mostrarán solo los modelos que utilizan el conjunto de entrenamiento balanceado, ya que estos obtuvieron mejores resultados ya que no se vieron perjudicados por el desbalance de clases.



6.2 Árbol de decisión

El primer modelo entrenado fue un **Árbol de Decisión**. Este modelo clasifica los datos mediante una serie de reglas sucesivas, separando las observaciones según los valores de las variables

predictoras. Una ventaja de este modelo es que resulta interpretable, ya que permite visualizar parte de las decisiones tomadas por el árbol.

El mejor Árbol de Decisión balanceado obtuvo los siguientes hiperparámetros:


`{'criterion': 'gini', 'max_depth': 20, 'min_samples_leaf': 75, 'min_samples_split': 100}`




Métricas

TRAIN:
ROC AUC: 0.9154
Accuracy: 0.8268
Precision: 0.8127
Recall: 0.8495
F1: 0.8307

TEST:
ROC AUC: 0.8665
Accuracy: 0.7870
Precision: 0.5230
Recall: 0.7859
F1: 0.6281





Análisis del Árbol de Decisión

El Árbol de Decisión balanceado obtuvo un rendimiento aceptable en el conjunto de prueba. En la matriz de confusión se observa que clasificó correctamente **8790 casos como “No llueve”** y **2603 casos como “Llueve”**. A su vez, cometió **2374 falsos positivos** y **709 falsos negativos**.

El modelo obtuvo un **Recall de 0.7859**, lo que significa que logró detectar aproximadamente el **78,59% de los días en los que efectivamente llovió**. Este resultado es importante porque en este problema se busca reducir los falsos negativos. Sin embargo, la **Precision fue de 0.5230**, lo que indica que el modelo también predijo lluvia en varios casos donde finalmente no llovió.

El **ROC AUC fue de 0.8665**, por lo que el modelo tiene una buena capacidad general para distinguir entre ambas clases. Al comparar train y test, se observa una baja en las métricas, especialmente en F1, lo que indica cierto grado de sobreajuste, esto se debe en parte al oversampling hecho, aunque el rendimiento en test sigue siendo razonable.

En cuanto a la importancia de variables, se observa que **Humidity3pm** fue la variable más relevante, seguida por **Pressure3pm**, **Sunshine**, **WindGustSpeed** y **Rainfall**. Esto es coherente con el problema, ya que la humedad, la presión, la cantidad de sol, el viento y la lluvia actual están relacionadas con la probabilidad de lluvia al día siguiente.

Explicación de las reglas del árbol

En la visualización del árbol se observa que la primera división se realiza con la variable Humidity3pm:

$\text{Humidity3pm} \leq 64.5$

Esto indica que el modelo considera la humedad a las 3 p. m. como la variable principal para separar los casos.

Si $\text{Humidity3pm} \leq 64.5$, el árbol tiende a clasificar los registros como “**No llueve**”. Dentro de esa rama, la siguiente regla usa $\text{Sunshine} \leq 8.95$, lo que indica que, aún con humedad menor, la cantidad de horas de sol también influye en la decisión.

En cambio, si $\text{Humidity3pm} > 64.5$, el árbol se dirige hacia una rama con mayor probabilidad de lluvia. Allí aparece otra división:

$\text{Humidity3pm} \leq 78.5$

Esto muestra que valores más altos de humedad aumentan la probabilidad de que el modelo clasifique el caso como “**Llueve**”.



En resumen, las primeras reglas del árbol muestran que el modelo basa gran parte de sus decisiones en la humedad a las 3 p. m. y en la cantidad de horas de sol, variables que tienen sentido desde el punto de vista meteorológico.

6.3 Random Forest

El segundo modelo entrenado fue **Random Forest**. Este modelo combina múltiples árboles de decisión y realiza la predicción final a partir del voto de los árboles. A diferencia de un único Árbol de Decisión, suele ser más robusto y menos propenso al sobreajuste, ya que no depende de una sola estructura de decisión.

El mejor Random Forest balanceado obtuvo los siguientes hiperparámetros:


```
{'criterion': 'gini', 'max_depth': 10, 'min_samples_leaf': 75, 'min_samples_split': 100, 'n_estimators': 200}
```




Métricas

TRAIN:
ROC AUC: 0.8965
Accuracy: 0.8118
Precision: 0.8149
Recall: 0.8068
F1: 0.8108

TEST:
ROC AUC: 0.8874
Accuracy: 0.8097
Precision: 0.5598
Recall: 0.7868
F1: 0.6542





Análisis de Random Forest

Random Forest balanceado obtuvo un **Recall de 0.7868** en el conjunto de prueba, muy similar al del Árbol de Decisión. Sin embargo, presentó mejores valores de **Precision, F1, Accuracy y ROC AUC**, lo que indica que el ensamble de árboles logró una mejor generalización que un árbol individual.

En la matriz de confusión se observa que el modelo clasificó correctamente **9115 casos como “No llueve”** y **2606 casos como “Llueve”**. Además, cometió **2049 falsos positivos** y **706 falsos negativos**. En comparación con el Árbol de Decisión, Random Forest redujo levemente los falsos negativos y disminuyó de forma más clara los falsos positivos, lo cual explica la mejora en Precision y F1.

El **ROC AUC fue de 0.8874**, superior al del Árbol de Decisión, lo que muestra una mejor capacidad general para distinguir entre días con lluvia y sin lluvia. Al comparar train y test, las métricas son bastante similares, por lo que no se observa un sobreajuste fuerte.

En cuanto a la importancia de variables, las más relevantes fueron **Humidity3pm, Sunshine, Pressure3pm, Rainfall, Pressure9am y RainToday**. Esto es coherente con el problema, ya que la humedad, la presión atmosférica, la lluvia del día actual y la cantidad de sol están directamente relacionadas con la probabilidad de lluvia al día siguiente.

Explicación del primer árbol representativo

En el primer árbol representativo del Random Forest se observa que la primera división también utiliza **Humidity3pm**:

$\text{Humidity3pm} \leq 64.5$

Esto indica que, dentro del bosque, la humedad a las 3 p. m. sigue siendo una variable clave para separar los casos. Si la humedad es menor o igual a 64.5, el árbol tiende a clasificar como “**No llueve**”. En esa rama aparece una regla asociada a **WindDir3pm_WNW**, es decir, la dirección del viento a las 3 p. m.

Si la humedad es mayor a 64.5, el árbol se dirige hacia una rama con mayor proporción de casos de lluvia. Allí se utiliza la variable **WindSpeed9am ≤ 14.0** , mostrando que, además de la humedad, el modelo también considera información relacionada con el viento.

En resumen, el árbol representativo muestra que Random Forest combina variables meteorológicas como humedad, viento, presión y lluvia actual para realizar la clasificación. A diferencia del Árbol de Decisión individual, este modelo no depende de un único árbol, sino del voto conjunto de muchos árboles, lo que mejora su estabilidad.



6.4 XGBoost

Como tercer modelo se entrenó **XGBoost**, un modelo basado en árboles de decisión que utiliza boosting. A diferencia de Random Forest, donde los árboles se entrenan de forma más independiente, en XGBoost los árboles se construyen de manera secuencial, intentando corregir los errores cometidos por los árboles anteriores.

El motivo de la elección fue que es un modelo más robusto y es mucho menos sensible a outliers, en comparación con otros modelos, tal como Regresión logística.

El mejor XGBoost balanceado obtuvo los siguientes hiperparámetros:

```
{'colsample_bytree': 1.0, 'learning_rate': 0.1, 'max_depth': 5, 'n_estimators': 200,  
'subsample': 0.8}
```



Métricas

TRAIN:
ROC AUC: 0.9405
Accuracy: 0.8619
Precision: 0.8581
Recall: 0.8672
F1: 0.8627

TEST:
ROC AUC: 0.9091
Accuracy: 0.8345
Precision: 0.6052
Recall: 0.7956
F1: 0.6875

Análisis de XGBoost

XGBoost balanceado obtuvo el mejor rendimiento general en el conjunto de prueba. Fue el modelo con mayores valores de **Accuracy, Precision, Recall, F1 y ROC AUC** entre los modelos evaluados.

En la matriz de confusión se observa que clasificó correctamente **9445 casos como “No llueve”** y **2635 casos como “Llueve”**. Además, cometió **1719 falsos positivos** y **677 falsos negativos**. Este último valor es especialmente importante, ya que fue el modelo con menor cantidad de falsos negativos, es decir, el que menos veces predijo que no llovería cuando en realidad sí llovió.

El modelo obtuvo un **Recall de 0.7956**, lo que indica que detectó aproximadamente el **79,56% de los días lluviosos reales**. También obtuvo una **Precision de 0.6052**, superior a la de los modelos anteriores, por lo que no solo detectó más casos de lluvia, sino que además redujo la cantidad de falsas alarmas.


El **ROC AUC fue de 0.9091**, el valor más alto entre los modelos comparados. Esto muestra que XGBoost tiene una muy buena capacidad para distinguir entre días con lluvia y sin lluvia.

Al comparar train y test, se observa una disminución moderada de las métricas, lo cual es esperable al evaluar sobre datos no vistos. Sin embargo, el rendimiento en test sigue siendo el mejor de todos los modelos, por lo que el modelo generaliza adecuadamente.

En resumen, XGBoost balanceado fue el modelo más adecuado para este problema, ya que logró el mejor equilibrio entre detectar días lluviosos y mantener un buen desempeño general. Su menor cantidad de falsos negativos justifica su elección como modelo final.

7. Comparación de modelos y conclusión final

	Modelo	Accuracy	Precision	Recall	F1	ROC AUC	TN	FP	FN	TP
0	Decision Tree balanceado	0.787027	0.523008	0.785930	0.628061	0.866485	8790	2374	709	2603
1	Random Forest balanceado	0.809685	0.559828	0.786836	0.654199	0.887446	9115	2049	706	2606
2	XGBoost balanceado	0.834485	0.605191	0.795592	0.687451	0.909127	9445	1719	677	2635



Arbol de decision: {'criterion': 'gini', 'max_depth': 20, 'min_samples_leaf': 75, 'min_samples_split': 100}

Random Forest: {'criterion': 'gini', 'max_depth': 10, 'min_samples_leaf': 75, 'min_samples_split': 100, 'n_estimators': 200}

XGBoost: {'colsample_bytree': 1.0, 'learning_rate': 0.1, 'max_depth': 5, 'n_estimators': 200, 'subsample': 0.8}

En base a los resultados obtenidos, se opta por elegir **XGBoost balanceado** como modelo final para realizar las predicciones. Esta elección se debe a que fue el modelo que obtuvo el mejor rendimiento general en el conjunto de prueba, alcanzando los valores más altos en Accuracy, Precision, Recall, F1 Score y ROC AUC entre los modelos evaluados.

En particular, se destaca su valor de **Recall**, que fue la métrica de mayor interés para este problema. Esto se debe a que se busca reducir la cantidad de falsos negativos, es decir, los casos en los que el modelo predice que no lloverá cuando en realidad sí llueve. En este contexto, este error se considera más grave que predecir lluvia cuando finalmente no ocurre.

Por lo tanto, XGBoost balanceado resulta el modelo más adecuado, ya que logra detectar una mayor proporción de días lluviosos y, al mismo tiempo, mantiene un buen desempeño general en el resto de las métricas.

EJ3: Modelos de Regresión

1. Descripción del dataset

El dataset utilizado contiene información de alojamientos publicados en la plataforma Airbnb para la ciudad de Copenhagen, Dinamarca, extraída en septiembre de 2025 desde Inside Airbnb. El objetivo es predecir el precio diario de alquiler (*price*) en coronas danesas (DKK) en función de la información publicada en los avisos.

El dataset original contiene 13,444 registros y 75 columnas que incluyen información sobre el alojamiento (tamaño, tipo, ubicación, comodidades), el host (antigüedad, verificación, tasa de respuesta), las reseñas (calificaciones, frecuencia) y la disponibilidad.

Fue necesario como primera etapa reducir el número de columnas, descartar los registros que no fueran útiles y preparar los datos para que puedan ser procesados para la regresión.

Variables destacables

Las variables que resultaron más relevantes para la predicción del precio fueron:


- **accommodates, bedrooms, bathrooms:** determinan el tamaño del alojamiento y son las variables con mayor coeficiente en la regresión lineal.
- **dist_centro_km:** variable calculada mediante la fórmula de Haversine, mide la distancia al centro de Copenhagen. Tiene una relación negativa con el precio.
- **neighbourhood_cleansed:** el barrio del alojamiento. Indre By (el centro histórico) tiene el mayor impacto positivo en el precio.

- **room_type:** tipo de alojamiento (completo, habitación privada o compartida). Las habitaciones privadas tienen un efecto negativo de -61 DKK.
- **amenities (36 categorías):** las ~2000 amenities únicas del dataset fueron categorizadas en 36 variables binarias (elevator, free_parking, premium_sound, has_ac, water_access, etc.).
- **availability_365:** días disponibles en el próximo año. Los alojamientos más caros tienden a tener mayor disponibilidad.

Transformaciones realizadas

Se realizaron las siguientes transformaciones sobre el dataset:

1. **Limpieza:** eliminación de columnas sin variabilidad, URLs, IDs, texto libre (escritas por el host del airbnb, por lo tanto siempre iban a ser positivas) y registros sin precio.
2. **Reducción de correlación:** variables altamente correlacionadas fueron reducidas. Las columnas de availability se redujeron solo a las de 365 días, se encontró una alta colinealidad con las columnas de review por lo que se mantuvo solo la de review general.
3. **Amenities:** categorización de ~2000 amenities únicas (estacionamiento, piscina, cocina, etc) en 36 variables binarias mediante análisis del listado completo.
4. **Fechas:** host_since, first_review y last_review convertidas a días transcurridos.
5. **Catóricas:** one-hot encoding de property_type (agrupando tipos con menos de 50 observaciones), room_type y neighbourhood.
6. **Nuevas variables:** dist_centro_km (se probó con distancia al centro vs distancia a atractivos turísticos y resultó mejor la primera opción), bedrooms_per_guest, bathrooms_per_guest, is_professional_host.
7. **Outliers:** eliminación de registros con z-score > 3 en la variable precio (~1.5% de los datos, fue la mejor opción entre conservar registros y mejorar la performance del modelo).



8. **Análisis de imágenes:** se exploró el uso del modelo CLIP para puntuar la calidad de las fotos de los listings, pero la correlación con el precio fue de solo 0.093 sobre una muestra de 500 imágenes, por lo que se descartó.

La partición de datos se realizó con un split 80/20 (entrenamiento/test) con random_state=42 para reproducibilidad.

2. Modelos entrenados

2.1 Regresión Lineal Múltiple


La regresión lineal múltiple ajusta una función de la forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$, donde cada coeficiente β representa el efecto marginal de la variable correspondiente sobre el precio, asumiendo que todas las demás variables se mantienen constantes. El modelo minimiza la suma de los errores cuadráticos entre los valores predichos y los reales.

Se utilizaron todas las variables resultantes del preprocesamiento, normalizadas con StandardScaler para que todas las variables queden en escalas comparables. Las features se escalaron solo en el conjunto de entrenamiento y se aplicó la misma transformación al conjunto de test para evitar data leakage.

Variables más influyentes

Los coeficientes estandarizados más altos fueron: accomodates (+174 DKK), bedrooms (+162 DKK), dist_centro_km (-148 DKK), availability_365 (+146 DKK), neighbourhood Indre By (+127 DKK) y bathrooms (+113 DKK). La interpretación es directa: a más huéspedes, más habitaciones y más cerca del centro, mayor precio.

Evaluación



	MAE	RMSE	R ²
Train	364 DKK	560 DKK	0.487
Test	366 DKK	545 DKK	0.478

El R² es similar en entrenamiento y test ($\Delta R^2 \approx 0.009$), lo que indica que no hay overfitting. Sin embargo, el modelo explica solo un 47.8% de la variación del precio. La limitación principal es que la relación entre las features y el precio no es lineal: el modelo no puede capturar que, por ejemplo, el efecto de agregar una habitación depende de la ubicación del alojamiento.


2.2 XGBoost

XGBoost (eXtreme Gradient Boosting) es un algoritmo de ensamble basado en árboles de decisión entrenados de forma secuencial: cada árbol nuevo se enfoca en corregir los errores del anterior. A diferencia de la regresión lineal, puede capturar relaciones no lineales e interacciones entre variables sin necesidad de crearlas manualmente.

Hiperparámetros y cross-validation

Se utilizó RandomizedSearchCV con 30 iteraciones y 5-fold cross-validation, optimizando R². Se exploró un espacio de hiperparámetros que incluyó n_estimators (200, 300), max_depth (3), learning_rate (0.01, 0.05), subsample (0.7, 0.8), regularización L1 (reg_alpha: 0, 0.1, 1), regularización L2 (reg_lambda: 1, 5, 10) y min_child_weight (1, 5, 10). La profundidad máxima se limitó a 3 tras observar overfitting con valores mayores en iteraciones previas.

Evaluación



	MAE	RMSE	R ²
Train	312 DKK	487 DKK	0.612
Test	332 DKK	505 DKK	0.552


El modelo presenta un overfitting controlado ($\Delta R^2 = 0.060$) y mejora un 7.4% en R^2 test respecto a la regresión lineal. Esta mejora se debe a su capacidad de capturar interacciones no lineales entre variables: XGBoost puede aprender, por ejemplo, que “Entire home + Indre By + 3 habitaciones” es un segmento con su propio rango de precios, sin necesidad de crear esa interacción manualmente.

2.3 Gradient Boosting (modelo a elección)

Se eligió Gradient Boosting de scikit-learn como tercer modelo porque, al ser conceptualmente similar a XGBoost pero con una implementación más simple (sin regularización L1/L2 ni las optimizaciones de velocidad de XGBoost), permite evaluar si la complejidad adicional de XGBoost se justifica en este problema.

Se utilizó cross-validation con 5 folds, obteniendo un R^2 promedio de CV consistente con los resultados finales.


Evaluación



	MAE	RMSE	R ²
Train	321 DKK	498 DKK	0.594
Test	337 DKK	516 DKK	0.532

El overfitting es similar al de XGBoost ($\Delta R^2 = 0.062$), pero el R^2 en test es 2 puntos porcentuales menor (0.532 vs 0.552). Esto confirma que la regularización L1/L2 de XGBoost aporta una mejora real, aunque modesta, que justifica su uso.

3. Cuadro comparativo de resultados (TEST)



Performance respecto al set de entrenamiento

La regresión lineal presenta prácticamente el mismo R² en train y test (0.487 vs 0.478), lo que indica ausencia de overfitting pero también un techo bajo en su capacidad predictiva. XGBoost y Gradient Boosting muestran un gap moderado entre train y test (~0.06), lo que es aceptable y señala que la regularización está cumpliendo su función de prevenir el sobreajuste.

Los tres modelos coinciden en que los precios altos (>3000 DKK) son los más difíciles de predecir, como se observa en los gráficos de Real vs Predicho donde la nube se dispersa significativamente en la zona de precios altos.

4. Elección del modelo

El modelo elegido es **XGBoost**, por las siguientes razones:

- **Mejor R² en test (0.552):** explica un 55% de la variación del precio, superando a la regresión lineal en un 7,4% y a Gradient Boosting en un 2%.
- **Overfitting controlado ($\Delta R^2 = 0.060$):** similar al de Gradient Boosting, lo que indica que el modelo generaliza bien a datos no vistos.
- **Captura interacciones no lineales:** puede modelar que el efecto combinado de habitaciones + ubicación no es aditivo sino multiplicativo, algo que la regresión lineal no puede hacer.

- **Regularización L1/L2:** controla la complejidad del modelo sin sacrificar performance, lo que explica la mejora sobre Gradient Boosting estándar.

EJ4: Clustering

4.1 Análisis Exploratorio

El conjunto de datos comprende información sobre algunos tracks (canciones) de Spotify.

Dimensión	Valor
Registros Totales	750
Columnas originales	13

Variable	Tipo	Descripción / Relevancia
acousticness	cuantitativa	Medida de confianza (0.0 a 1.0) de si la pista es acústica.
danceability	cuantitativa	Qué tan adecuada es una pista para bailar basándose en tempo, ritmo, fuerza del pulso y regularidad.
duration	cuantitativa	La duración de la pista expresada en milisegundos.
energy	cuantitativa	Medida perceptiva de intensidad y actividad. Valores entre 0.0 y 1.0, siendo 1.0 la más energética.
instrumentalness	cuantitativa	Predice si la pista no tiene voces. Valores cercanos a 1.0 indican que es instrumental.
key	Cualitativa	Los números mapean a notas usando notación estándar de clase de tono (0 = Do, 1 = Do#, etc.). -1 indica que no se detectó.
liveness	Cuantitativa	Detecta la presencia de audiencia en la grabación.
loudness	Cuantitativa	El volumen promedio de la pista en decibelios (dB). El rango de valores se encuentra típicamente entre -60 Db y 0 Db.
mode	cualitativa	Indica la modalidad (mayor o menor) de la escala. El modo Mayor es 1 y el Menor es 0.

speechiness	Cuantitativa	Detecta palabras habladas. De 0.0 a 1.0
tempo	cuantitativa	La velocidad o ritmo estimado de la pieza en BPM (Beats Per Minute)
time_signature	cualitativa	Estimación de cuántos pulsos hay en cada compás. Rango de 3 a 7.
valence	cuantitativa	Medida de la positividad musical. Valores altos suenan alegres o eufóricos. Rango entre 0.0 y 1.0

Se observaron valores que no pertenecen al dominio. Por su porcentaje de 0.8% en relación a la cantidad de registros totales, los eliminamos.

Se decidió categorizar la variable `time_signature` como cualitativa nominal basándose en los siguientes criterios técnicos:


- Ausencia de Linealidad y Escala: Aunque se representa numéricamente (ej. 3, 4, 5), estos valores funcionan como etiquetas de categorías rítmicas. No existe una relación de orden o magnitud real; un compás de 4/4 no es "superior" a uno de 3/4, ni la "distancia" entre ellos tiene un significado físico que el algoritmo deba promediar.
- Prevención de Sesgo en el Modelo: Al tratarla como cuantitativa, el escalado le asignaría un peso artificial basado en su varianza. Dado que la gran mayoría de las canciones comerciales operan en 4/4, cualquier otra firma rítmica sería interpretada erróneamente por K-Means como un outlier extremo, alejando esas canciones de sus clusters naturales solo por una diferencia de compás.

4.2 Análisis de la tendencia y cantidad de clusters

Escalamos los datos y, mediante el estadístico de Hopkins, observamos una clara tendencia a formar clusters dado el elevado valor de 0.7842.

4.2.1 Regla del codo y Análisis de Silhouette


Realizamos una estimación mediante la regla del codo y notamos un quiebre pronunciado en $K=2$.



Luego, confirmamos con el método de Silhouette que $k=2$ es el valor que maximiza el coeficiente en el análisis.




Se utilizó un análisis de medias mediante un gráfico de barras agrupadas para caracterizar los grupos resultantes con escala de 0 a 1. Se decidió observar a *tempo* y *loudness* dado que su escala afecta a los otros valores, por lo que es mejor analizarlas por separado.




Cluster	Tempo	Loudness
0	113.759594	-13.292912
1	123.808533	-6.212808

4.3 Análisis de la calidad de los clusters


Sin embargo, observando el análisis mediante PCA que se encuentra abajo notaremos como el cluster que agrupa temas más enérgicos es más homogéneo que el aquel cuyas canciones tienen valores altos de *acousticness*, y bajos en *speechiness* y *loudness*.



Esto nos sugiere que podríamos encontrar dos subperfiles dentro del que ya teníamos. Por ende, decidimos agrandar la cantidad de grupos a $K = 3$ y observamos lo siguiente:



Ahora uno de los clusters presenta un valor de *instrumentality* considerablemente más elevado que los demás. Sumado a un nivel muy bajo de *speechiness* podemos relacionar este conjunto de temas al género instrumental y atmosféricos. Es decir, con K=2 observábamos un cluster que engloba tanto a temas de jazz, country y géneros similares como a piezas de música clásica y de ambiente. Veamos como se ve el gráfico con PCA ahora:



Finalmente, mientras que el Cluster 1 captura la música de alta energía y producción como el pop, rock y la electrónica, el modelo logra ahora subdividir el espectro orgánico. El Cluster 0 se caracteriza por una *instrumentalness* extrema y mínima *energy*, representando piezas atmosféricas o clásicas, mientras que el Cluster 2 agrupa el contenido de canciones con intensidad media, con voces presentes pero arreglos orgánicos (Indie, Jazz vocal, Acústicos tranquilos). Esta segmentación tripartita dada por K=3 ofrece una resolución mucho más fiel a la diversidad del catálogo de Spotify analizado.

Bibliografía

Ejercicio 1 — Yellow Cab NYC

Dataset: Yellow Cab NYC — Viajes de abril, mayo y junio de 2025 **Fuente:** NYC Taxi and Limousine Commission (TLC)

- Data dictionary: https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_yellow.pdf
- Flex Fare report: https://www.nyc.gov/assets/tlc/downloads/pdf/flex_fare_pilot_report_06_2019.pdf
- Taxi fare: <https://www.nyc.gov/site/tlc/passengers/taxi-fare.page>

- Tolls: <https://www.mta.info/fares-tolls/tolls/congestion-relief-zone/taxi-fhv-tolls>
- Cobertura celular Manhattan:
<https://www.timeout.com/newyork/blog/the-worst-cell-reception-in-new-york-is-in-this-manhattan-neighborhood-090716>
- Dead zones celulares:
<https://esim.holafly.com/research/us-cities-with-most-cell-signal-dead-zone/>

Ejercicio 2 — Clima Australia

Dataset:

- - <https://www.kaggle.com/datasets/jsphyg/weather-dataset-rattle-package/data> - Queensland, Victoria, Australia Meridional, Australia Occidental

Ejercicio 3 — Airbnb Copenhagen

Dataset: Airbnb listings — Copenhagen, Hovedstaden, Denmark — September 2025 **Fuente:** Inside Airbnb

- Data dictionary:
<https://docs.google.com/spreadsheets/d/1iWCNJcSutYqpULSQHINyGlnUvHg2BoUGoNRIGa6Szc4/edit?gid=1322284596#gid=1322284596>
- Data source:
<https://data.insideairbnb.com/denmark/hovedstaden/copenhagen/2025-09-29/data/listings.csv.gz>

Ejercicio 4 — Spotify

- Spotify for developers:
<https://developer.spotify.com/documentation/web-api/reference/get-several-audio-features>

Tiempo dedicado

Integrante	Tarea	Prom. Hs Semana
------------	-------	-----------------

Malena Sein	EJ1	6
Candela Piccin	EJ1	6
Alexis maximiliano Torres Vargas	EJ2	6
Javier Zardain	EJ3	6
Bruno Pezman	EJ4	6